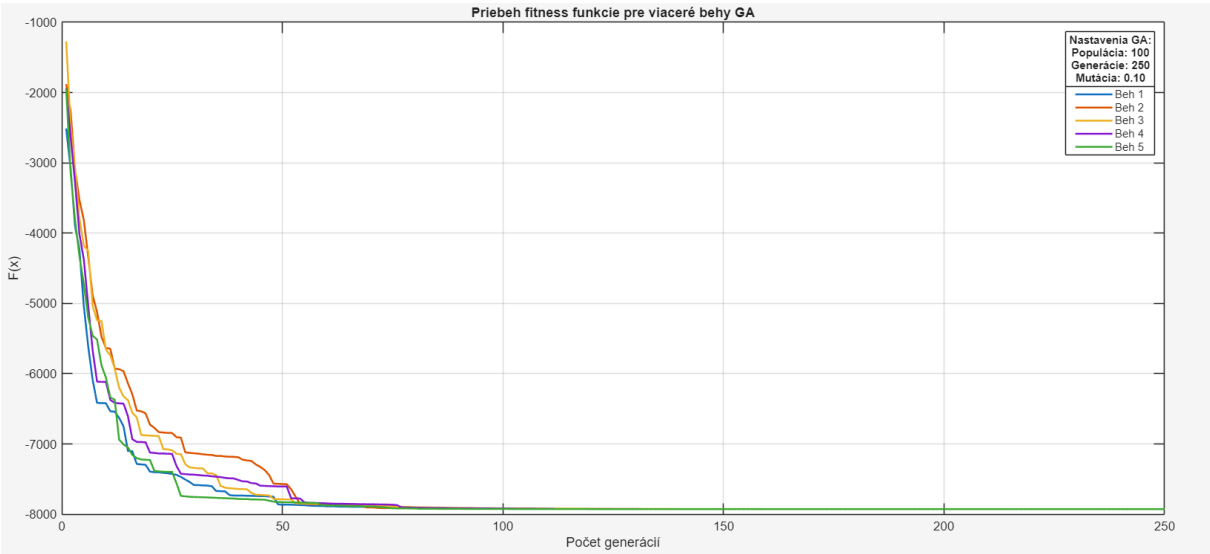

Vidiet, ze pri populacii 100 a mutacii 0.1 vsetky grafy konverguju niekde okolo 70/80 generacii a vsetkym sa uspesne podarilo nasjt minimum.

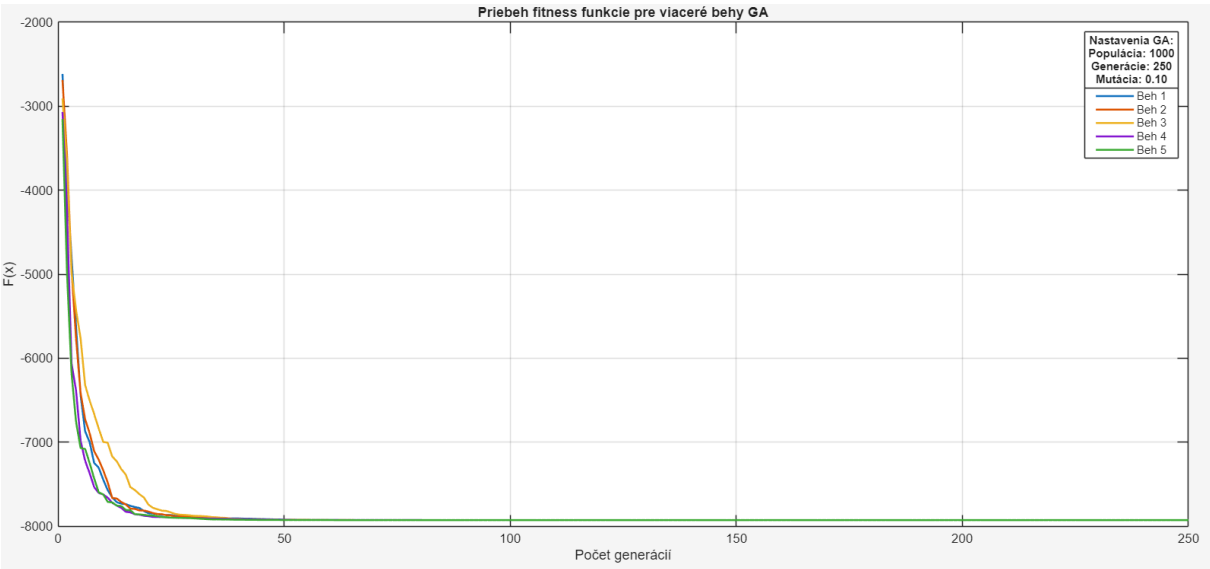

Z porovnania grafov vyplýva, že desaťnásobné zväčšenie veľkosti populácie (zo 100 na 1000 jedincov) viedlo k výrazne rýchlejšej konvergencii, pričom algoritmus dosiahol globálne minimum už v prvých desiatkach generácií.

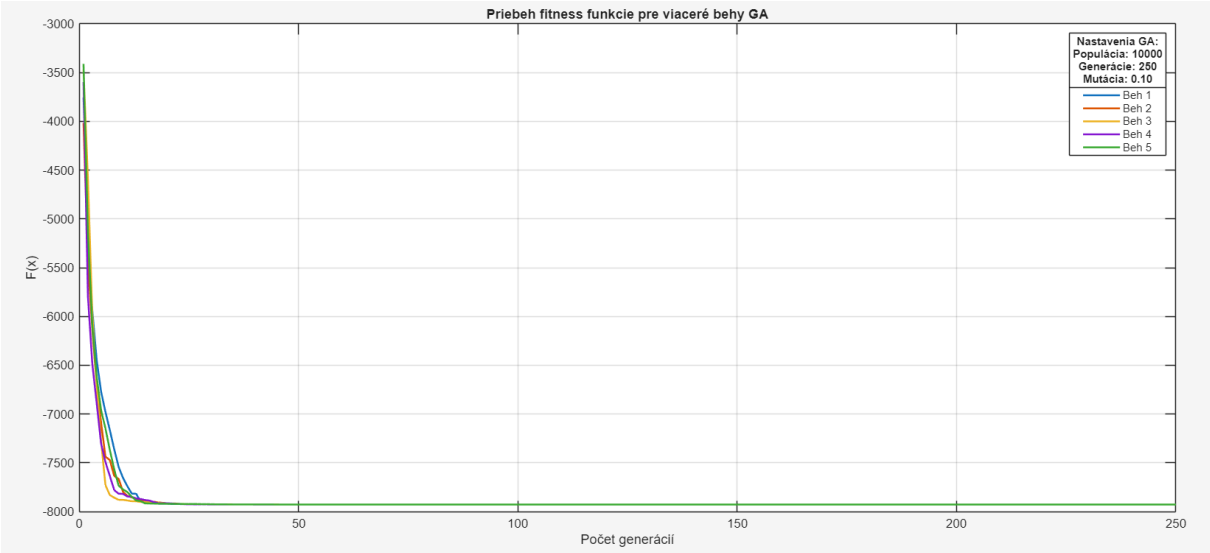

Pri populácii 100 jedincov sú medzi jednotlivými behmi v úvodných fázach výraznejšie rozdiely a algoritmus potrebuje približne 50 až 80 generácií na ustálenie v globálnom minime.

Zvýšenie veľkosti populácie na 1 000, a následne až na 10 000 jedincov, prináša oveľa strmší pokles účelovej funkcie hneď v prvých generáciách. Väčšie množstvo jedincov zabezpečí lepšie počiatočné preskúmanie priestoru, čo minimalizuje rozptyl medzi jednotlivými behmi. Pri populácii 10 000 je rozdiel medzi behmi takmer neviditeľný a algoritmus nachádza optimálne riešenie s vysokou spoľahlivosťou už v priebehu prvých 10 až 20 generácií.

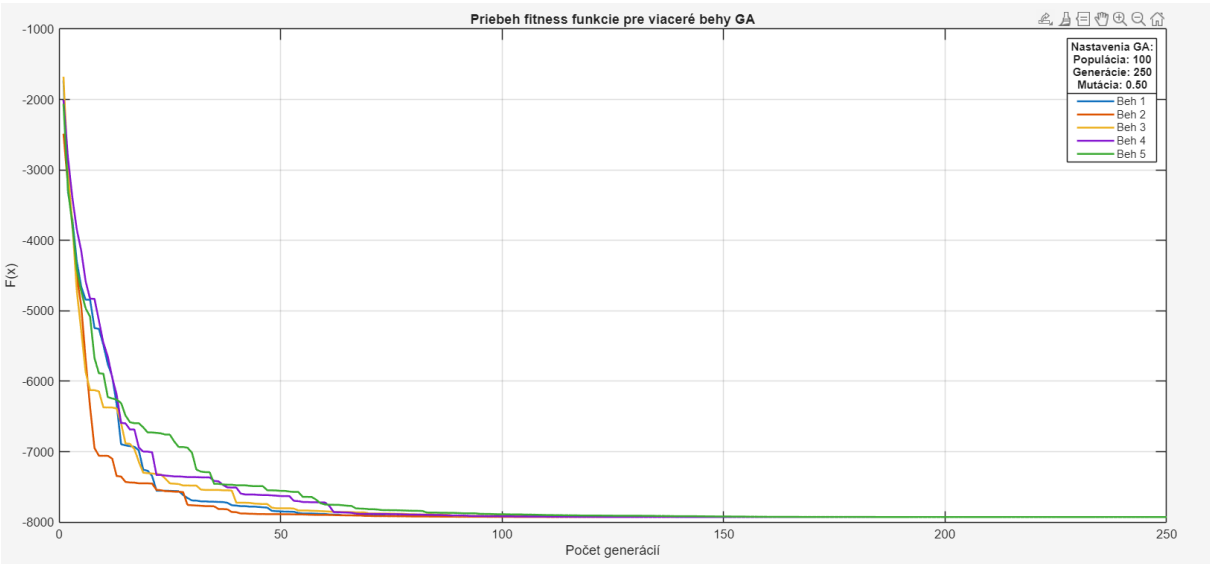

Pri výraznom zvýšení pravdepodobnosti mutácie na 50 % môžeme v grafe pozorovať "schodovitejší" a menej plynulý priebeh konvergencie, čo je následkom častých a veľkých náhodných zmien

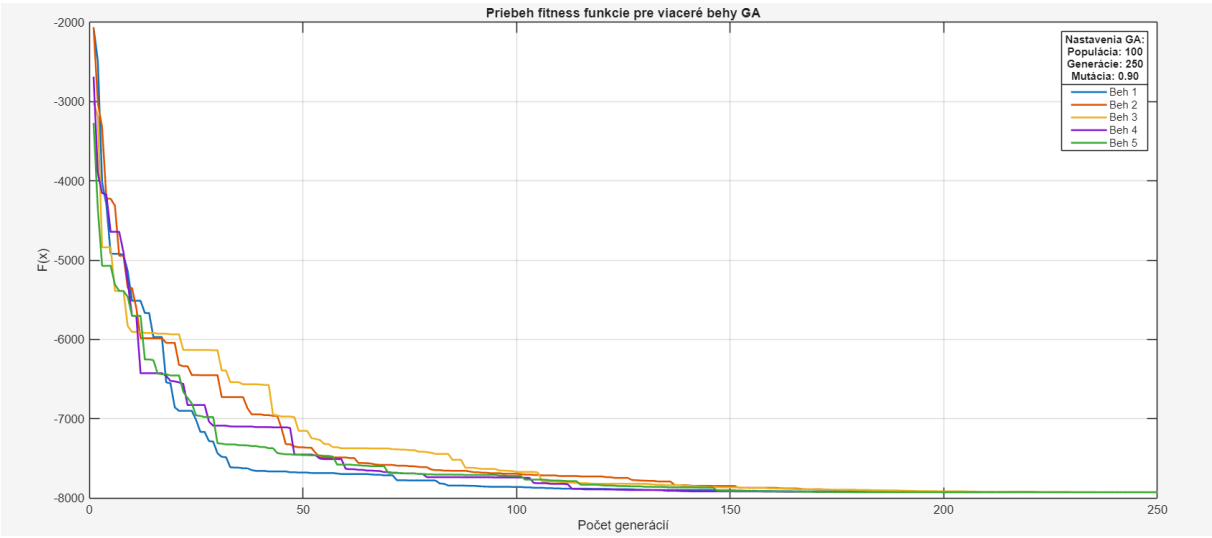

Priebeh účelovej funkcie je výrazne kaskádovitý a pomalší, čo naznačuje, že algoritmus funguje skôr ako čiastočne náhodné generovanie novej populácie než riadená evolúcia.

BONUS A

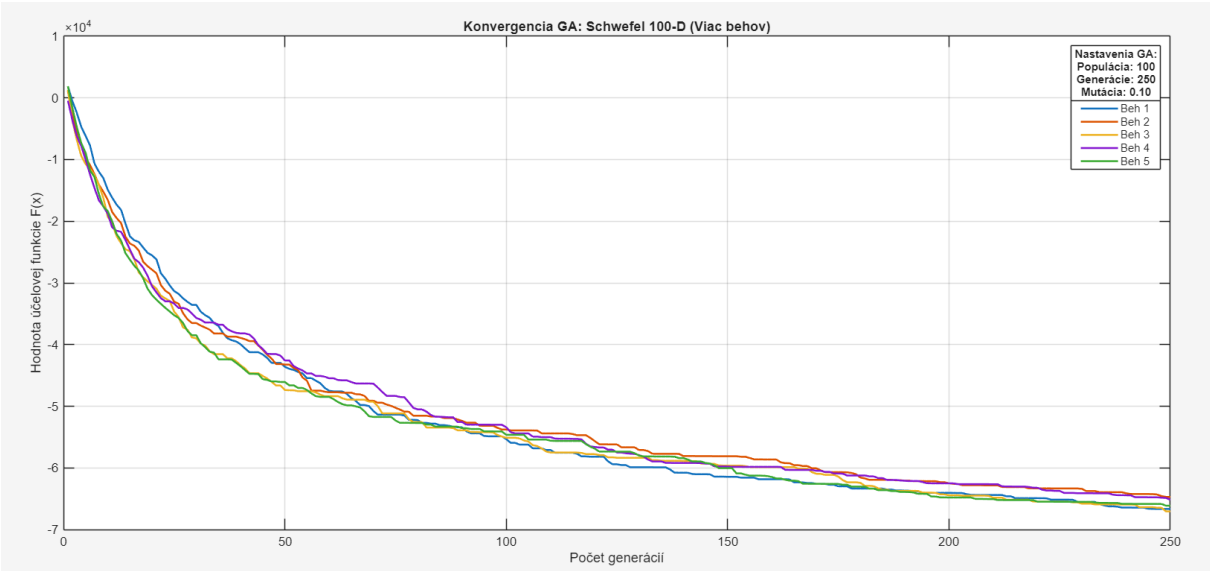

Pri rozšírení problému na 100 premenných sa prehľadávaný priestor extrémne zväčšil. Z grafu je zrejmé, že algoritmus aj s nastavením populácie na 100 jedincov spoľahlivo a plynule konverguje smerom nadol. Kvôli vysokemu obmedzenému počtu generácií (250) síce algoritmus ešte nedosiahol úplné teoretické minimum (cca -79272), ale trend kriviek jasne ukazuje stabilné vylepšovanie riešenia.

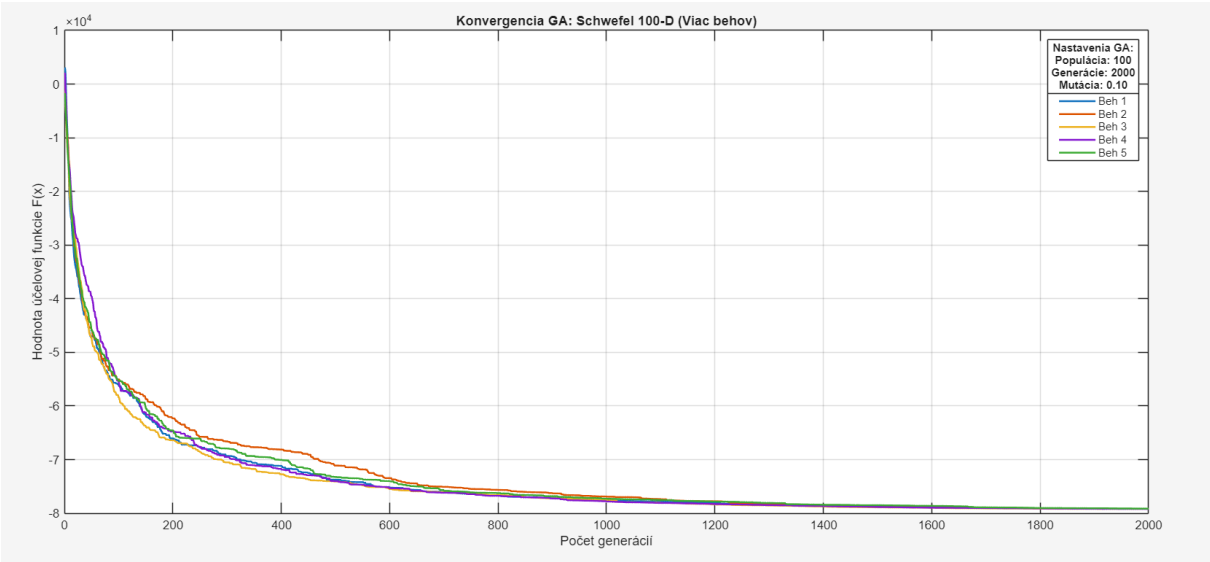

zvýšenie limitu na 2000 generácií mu poskytlo dostatok priestoru na dôkladnú evolúciu. Z grafu je zrejmé, že po počiatočnom strmom poklese sa konvergencia postupne spomaľuje a vyhladzuje.

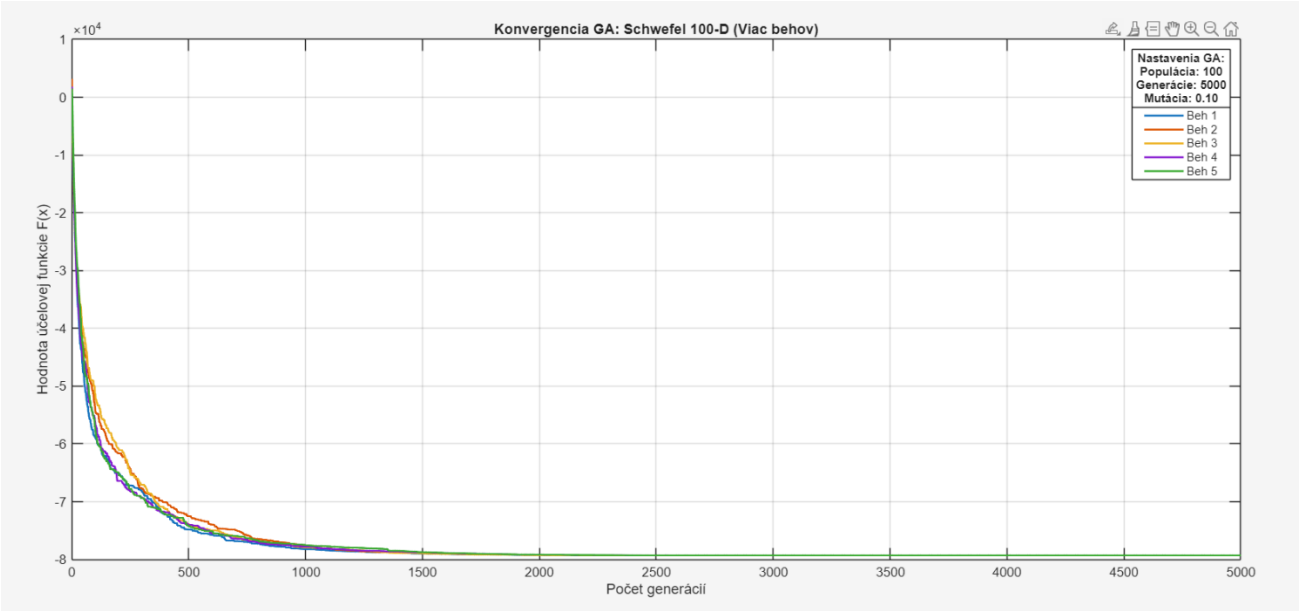

Zvýšenie limitu na 5000 generácií pri 100-rozmernej Novej Schwefelovej funkcii poskytlo algoritmu dostatočný priestor na úplnú konvergenciu.

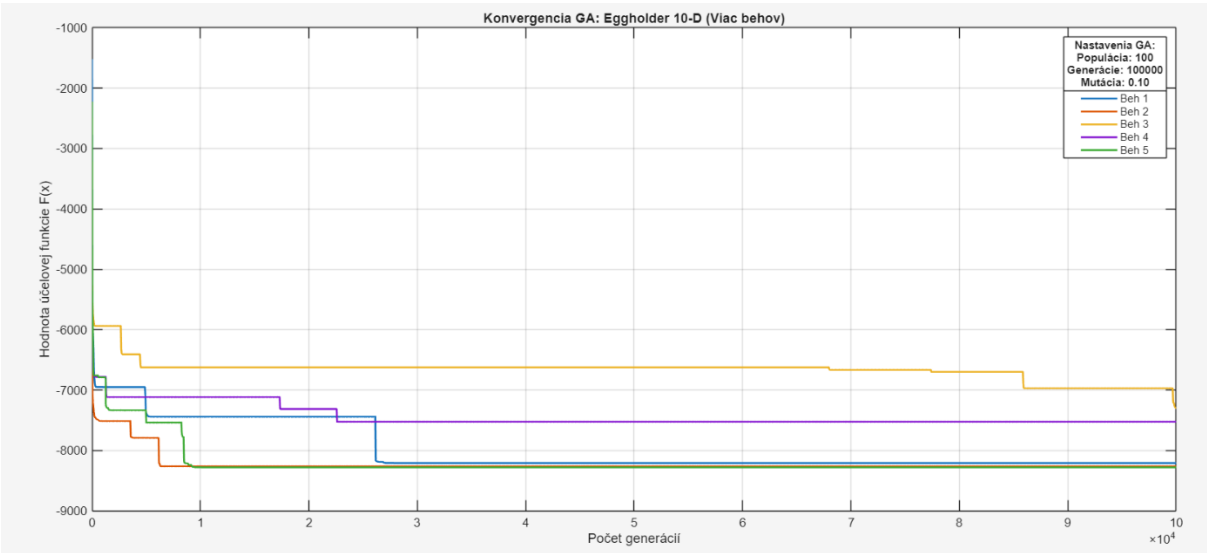

Tento graf ukazuje klasický problém pri optimalizácii zložitejších funkcií – algoritmus uviazol v lokálnych minimách

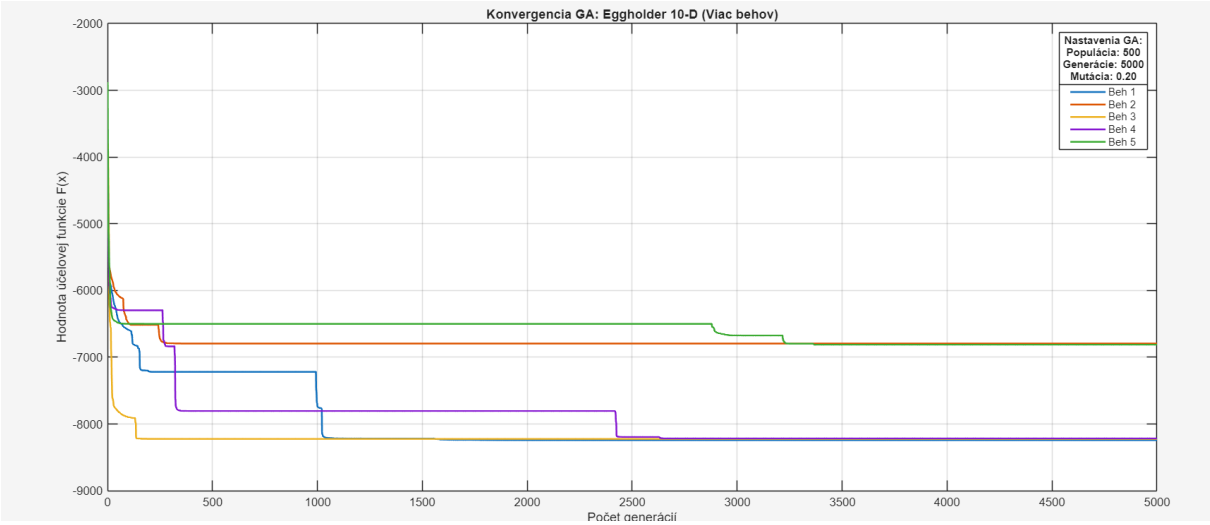

Aj po zvýšení populácie a miery mutácie môžeme na grafe funkcie Eggholder pozorovať schodovitý priebeh, ktorý jasne potvrdzuje jej extrémne zložitý povrch plný lokálnych miním.

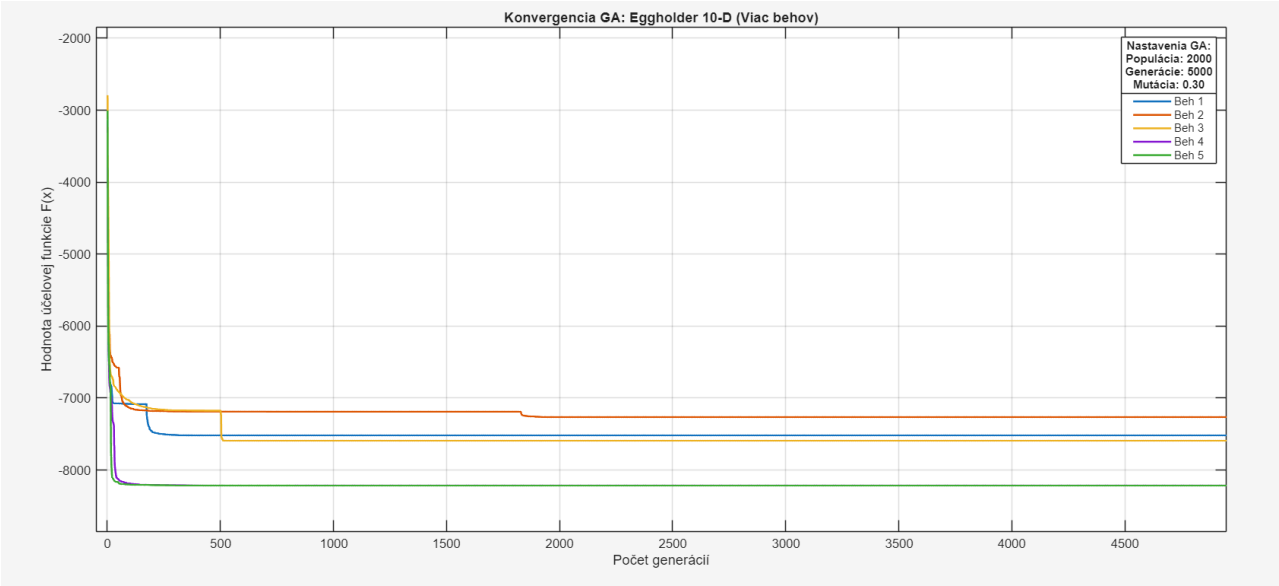

Nahradenie klasického viacbodového kríženia za medziľahlé kríženie (intmedx) zásadne zlepšilo schopnosť algoritmu generovať nové riešenia v spojitom priestore. Ako však ukazuje graf, funkcia Eggholder je natoľko extrémne zložitá, že stále iba dve funkcie dosiahli minimum.