Klasický prístup UI – symbolový
(„GOFAI“ – Good Old Fashion AI)
Inteligencia stroja pochádza
od človeka – analytika, programátora:
if-then, if-else-then

Moderný prístup UI – subsymbolový

Štatistický model, neurónové siete, strojové učenie.

Stroj sa naučí sám z dát alebo z interakcie s prostredím

(Strojové učenie)

2. Umelé neurónové siete (UNS)
Úvod do problematiky

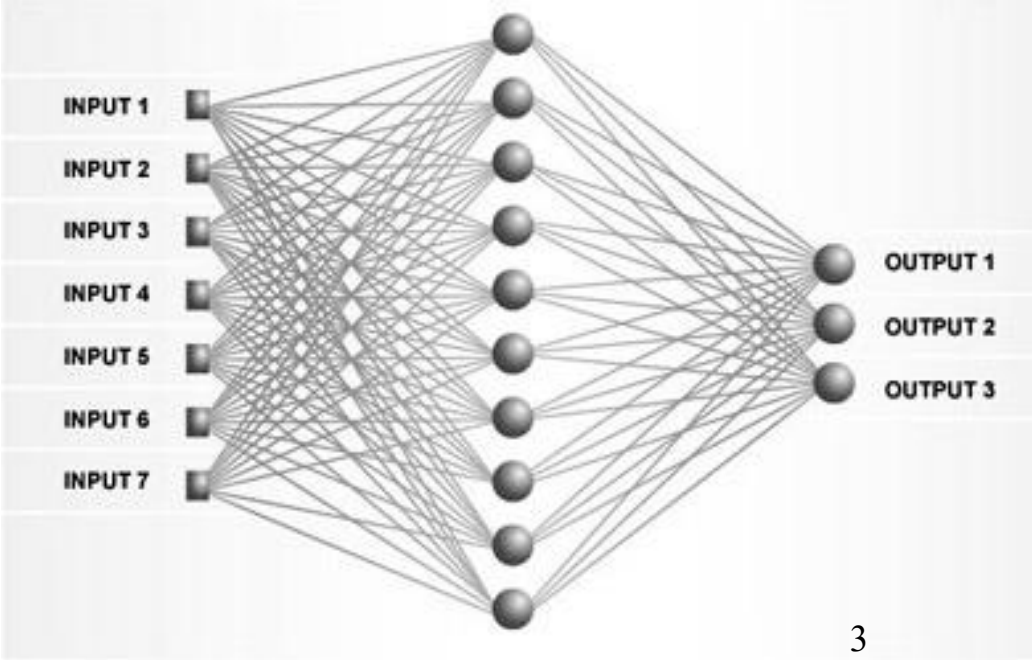

2.1 Mozog, biologické neuróny, história vývoja UNS

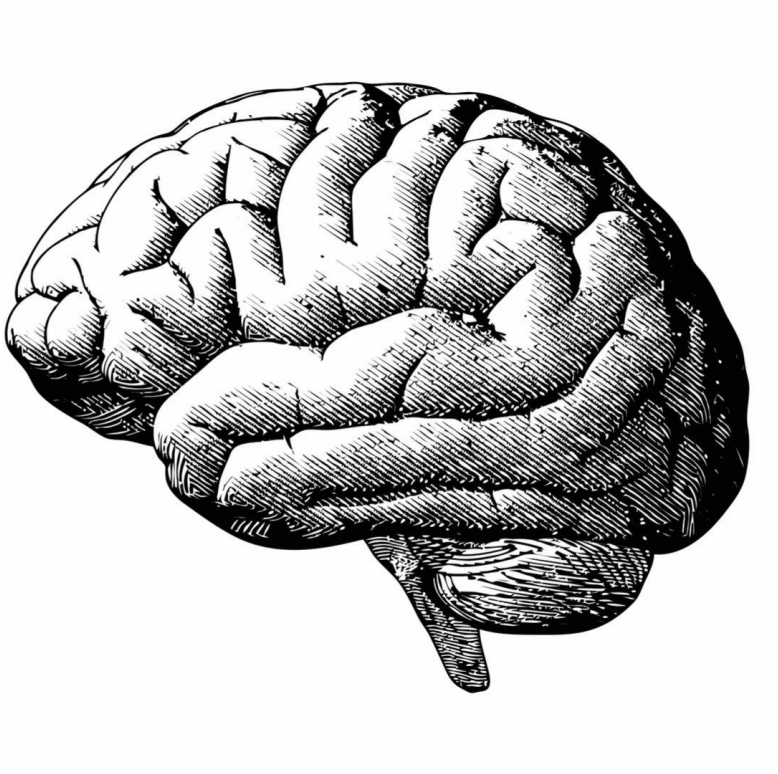

Neuróny

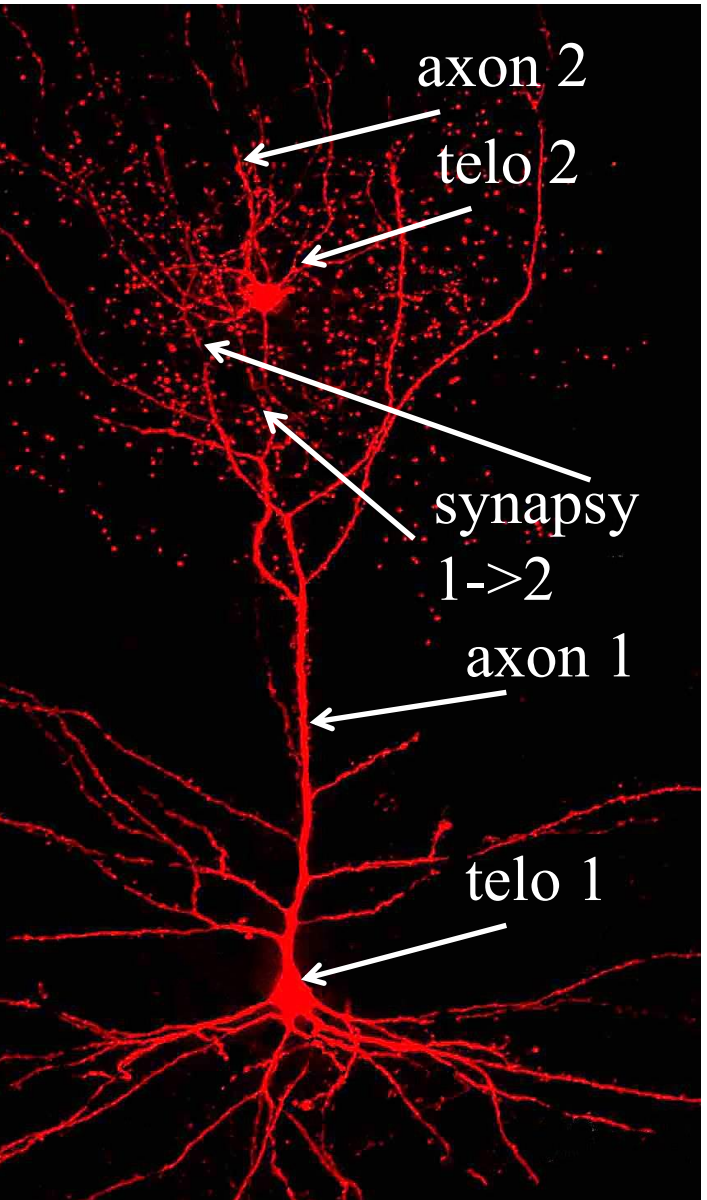
axon 2
telo 2
synapsy
1->2
axon 1
telo 1

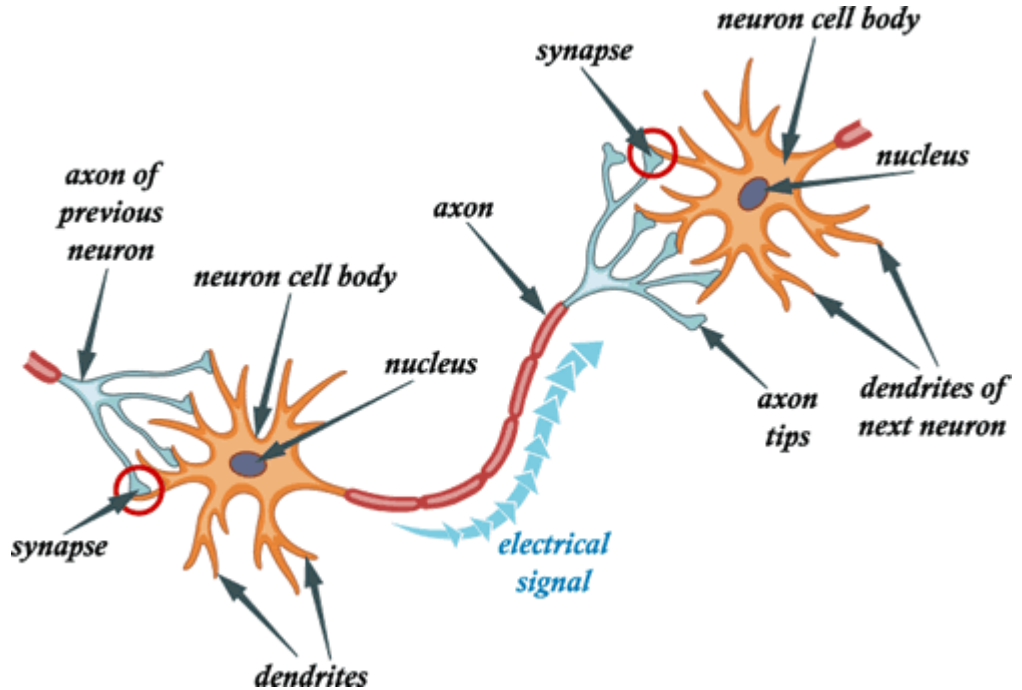
neuron cell body
synapse
nucleus
axon of
previous
neuron
axon
neuron cell body
nucleus
axon
tips
dendrites of
next neuron
synapse
electrical
signal
dendrites

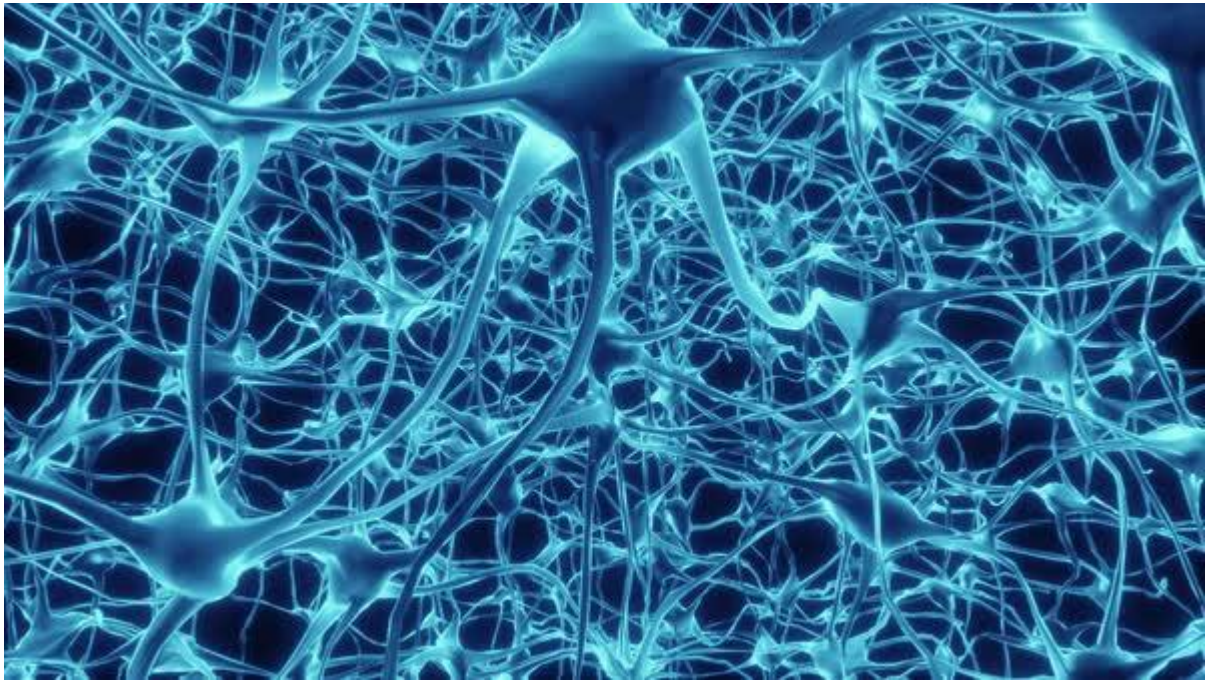

Počet neurónov niektorých živočíchov

	Počet neurónov	Počet synapsií
Caenorhabditis elegans (červ)	302	7500
Vínna muška	250 000	10^7
Mravec	250 000	
Včela	960 000	10^9
Myš domáca	71 000 000	10^{12}
Potkan hnedý	200 000 000	$4{,}5.10^{11}$
Mačka	760 000 000	10^{13}
Pes	2 253 000 000	
Šimpanz	28 000 000 000	
Človek	86 000 000 000	$1{,}5.10^{14}$
Slon africký	257 000 000 000	

Prenos el. signálov medzi neurónmi v mozgu

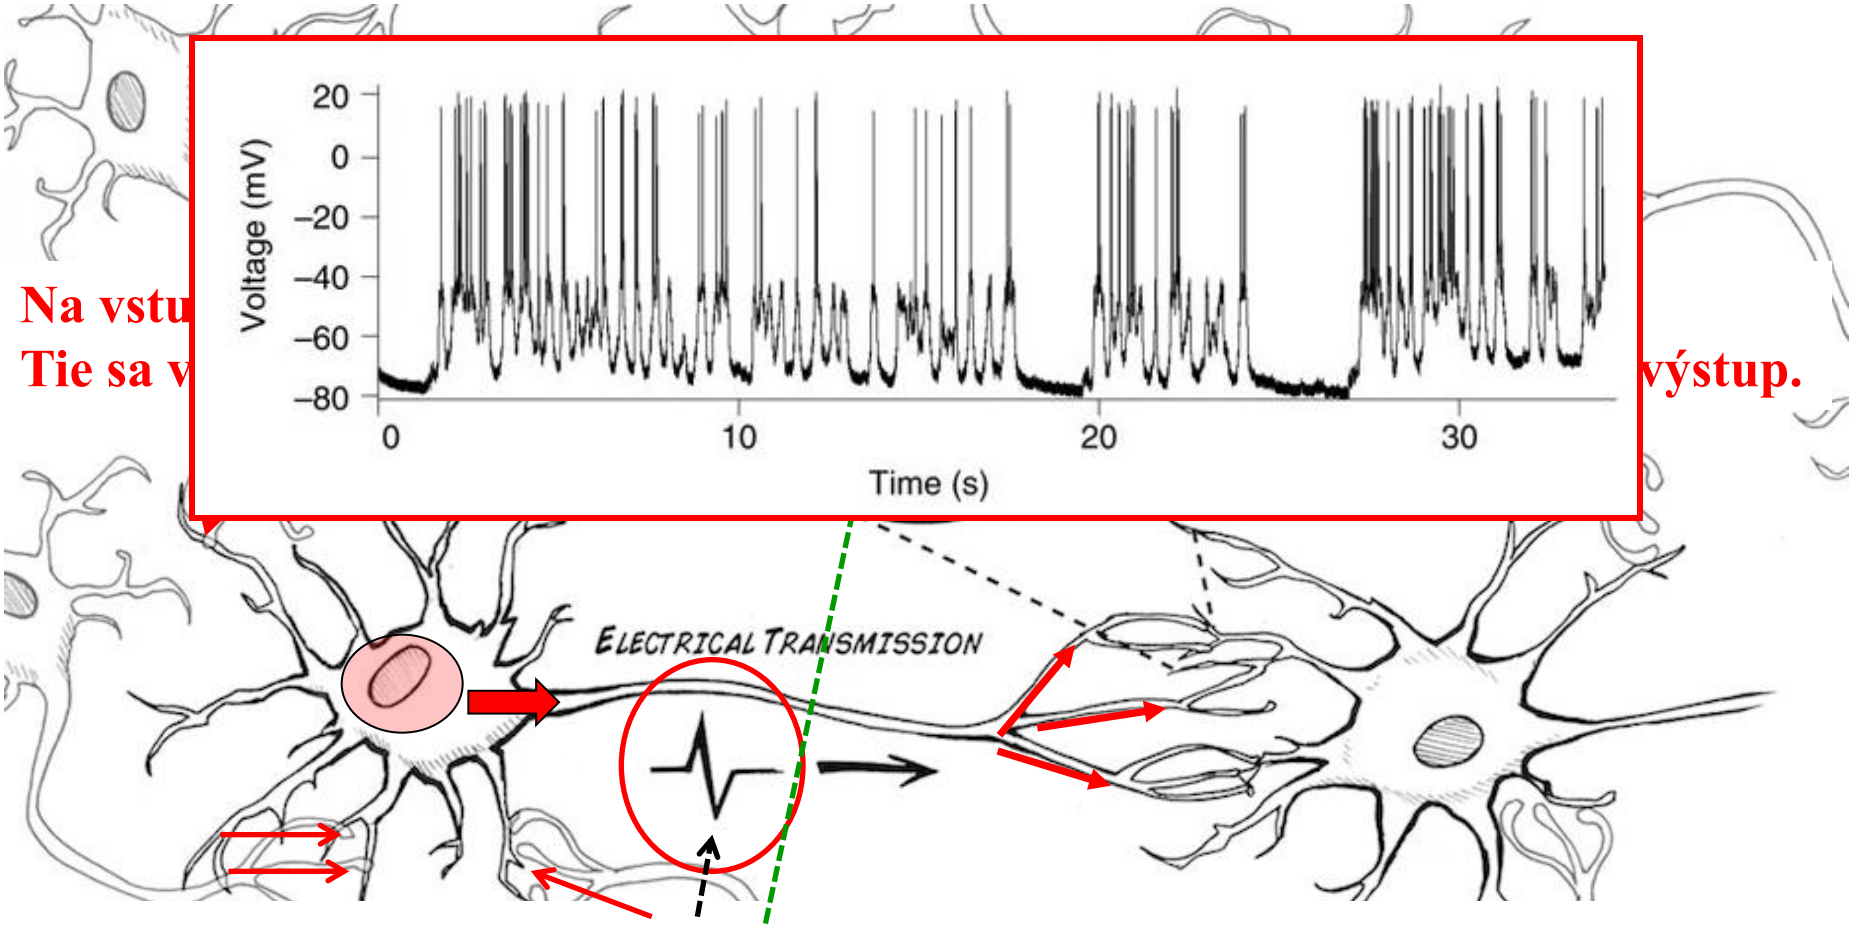

Na vstu

Tie sa v

výstup.

Impulzy z jadra s ferkvenciou *f* sa šíria cez axon na dendrity iných neurónov.

Hodnota *f* je priamo úmerná sumárnej excitácii nurónu z jeho vstupov.

Na prenos impulzov má vplyv tiež koncentrácia neuroprenášačov (neurotransmiterov) a stav chemického prostredia v mozgu.

Synapsia

elektrický prenos impulzu
(informácie)

chemický prenos
impulzu

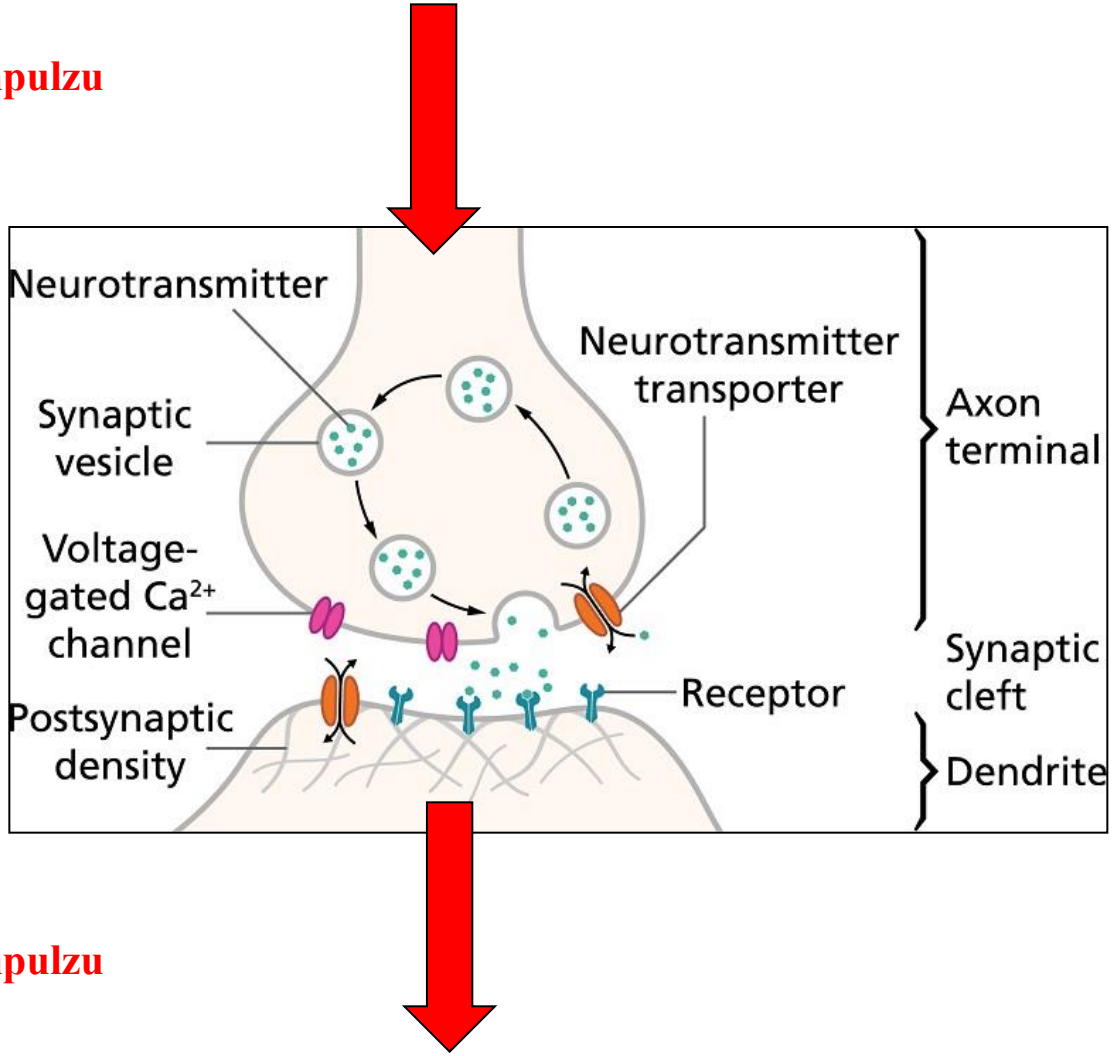

elektrický prenos impulzu

Synaptické spojenie dvoch neurónov

chemický prenos
(u cicavcov) , 500 μs

elektrický prenos,
70 mV (NA^+, Cl^-),
120 m/s

elektrický prenos

synapsa jedného neurónu

dendrid iného neurónu

Rýchlosť pohybu el. náboja v el. obvodoch je 10^6 x väčšia. (stovky MHz / stovky Hz)

Činnosť jedného neurónu

- **ak suma všetkých vstupných potenciálov v danom okamžiku presiahne prahovú hodnotu - aktivácia neurónu, jadro po axone vyšle impulz, ktorý je distribuovaný do všetkých synáps**
- **na** … **y** **im** … **mi je** **20-**

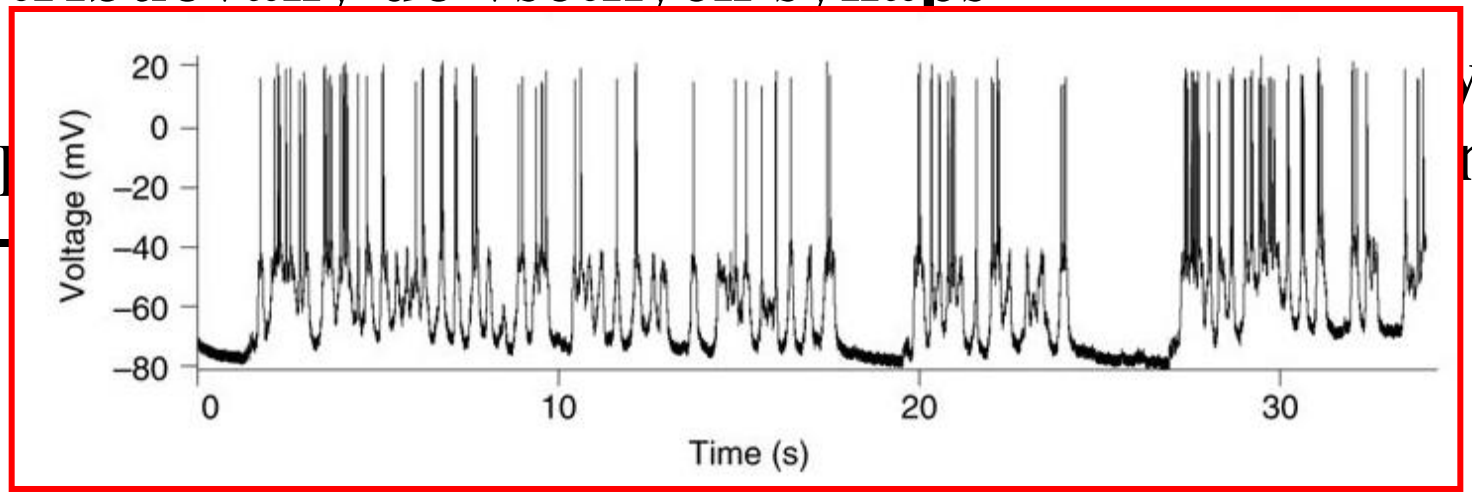

zhluky impulzov s frekvenciou 250-1000 impulzov / s, frekvencia zhlukov 1-10 zhlukov za sekundu (frekvenčná modulácia)

Centrálna nervová sústava je hlavné nervové riadiace centrum vyšších organizmov.
Skladá sa z dvoch základných súčastí: mozgu (1) a miechy (2,3).

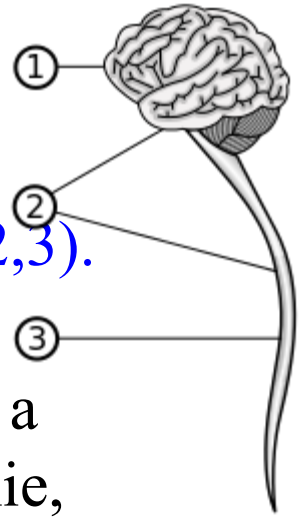

CNS riadi motorické reakcie organizmu, koordinuje pohyb a rovnováhu, nesie centrá životne dôležitých funkcií (dýchanie, krvný obeh, hlad, smäd..), je centrom vnímania, uvažovania, pamäte, učenia a vedomia človeka (kognitívnych funkcií).

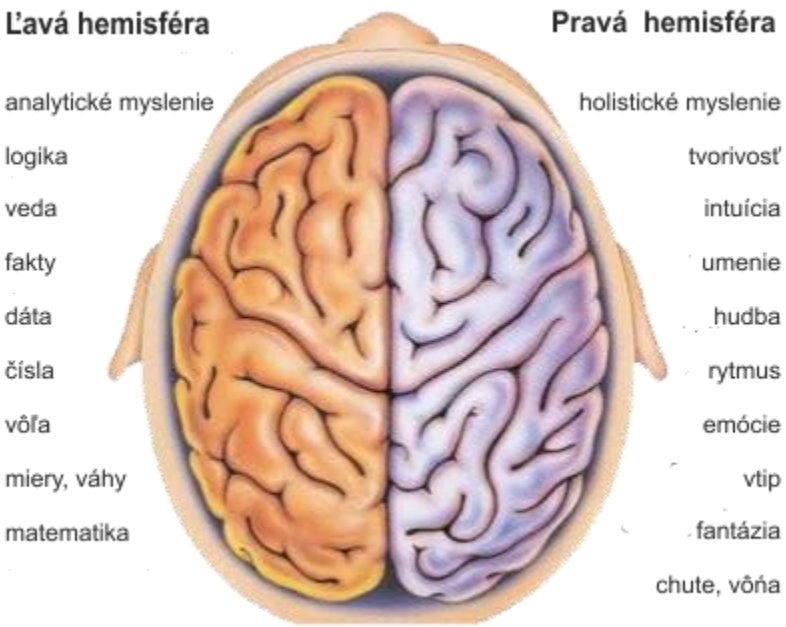

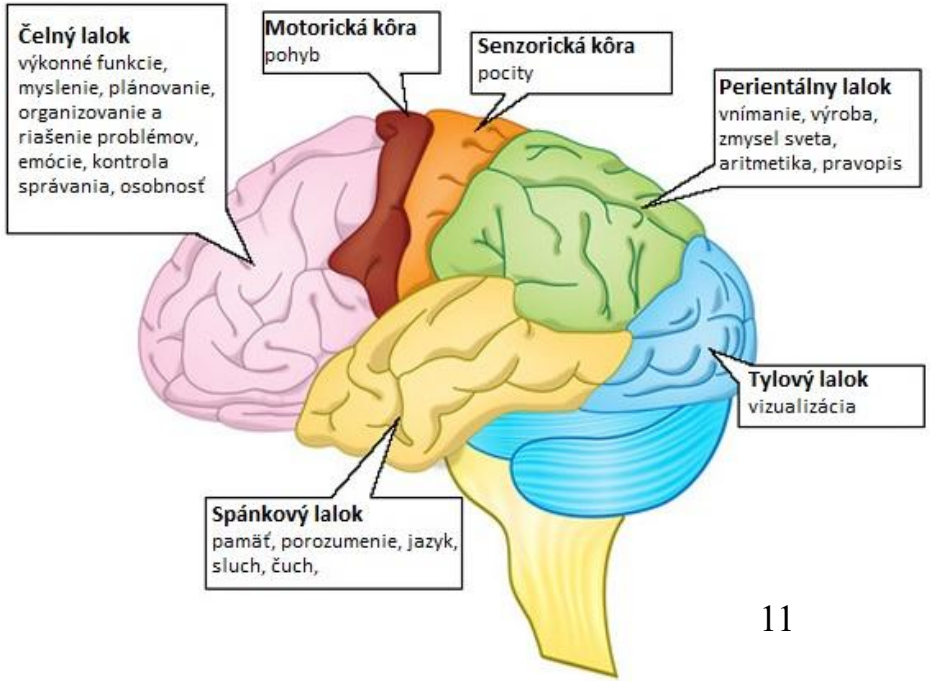

Biologické neuróny a motivácia vzniku umelých neurónových sietí (UNS)

- **Ľudský mozog = 86 miliárd neurónov, každý neurón je spojený s asi 10 000 ďalšími neurónmi**
- **paralelné spracovanie informácií (vnemov, myšlienok, akcií ...)**
- **schopnosť sa učiť zo skúseností, z príkladov, z analógie**
- **modifikovať znalosti, zovšeobecňovať, konkretizovať, autoasociácia / heteroasociácia – samozdokonaľovanie sa**
- **funkcia mozgu ? (ako mozog myslí, čo je to vedomie, ...)**

- **klasická výpoč. tech. - vopred daný algoritmus (program), pomocou ktorého sa sekvenčne spracovávajú informácie, centrálne riadenie výpočtu**
- **mozog - veľký počet rôznych druhov spracovaní informácií súčasne (nezávisle ?) bez centrálneho programu:**

  - vyhodnocovanie obrazu, zvuku, hmatu, teploty ...
  - spracovanie informácií z týchto vnemov, vyhodnocovanie situácie, klasifikácia objektov a javov
  - uvažovanie, učenie sa, rozhodnutie o adekvátnych akciách
  - realizácia akcie, hrubá motorika, jemná motorika
  - súčasné vykonávanie viacerých nezávislých činností
  - popritom riadenie (zložitých) funkcií organizmu

- **biologické neuróny pracujú o 6 rádov pomalšie než kremíkové hradlá (ms vs. ns)**
- **napriek tomu v mnohých ohľadoch je ľudský mozog ešte stále výkonnejší než súčasné najvýkonnejšie počítače**
- **činnosť mozgu je založená na <u>procese učenia</u> sa (prispôsobovania sa, korigovania znalostí) a neskôr na využití týchto schopností a znalostí vo <u>fáze vybavovania</u> (využitie znalostí, schopností)**

Príklady tvorivých schopností mozgu

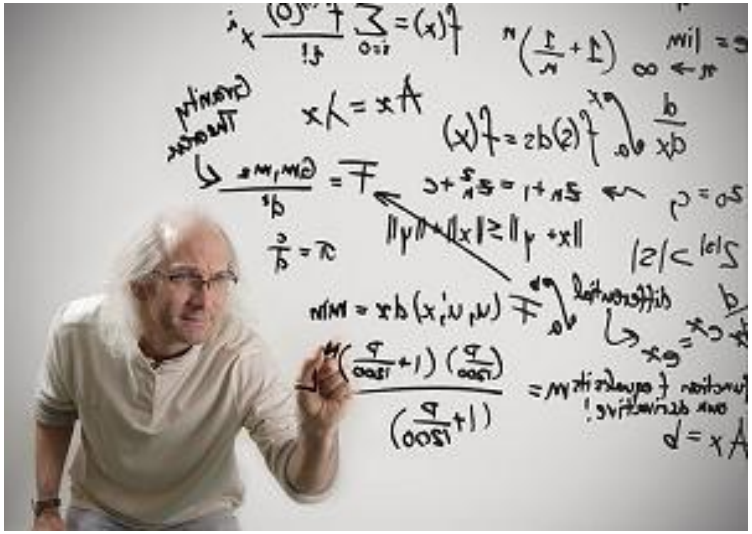

Príklady schopností mozgu

Proces získania zručností/znalostí – trénovanie/učenie

Cieľ nášho snaženia

napodobenie architektúry / funkcií biologických neurónových systémov a
ich využitie pre rôzne praktické (technické, výpočtové) účely → "umelé neurónové siete" a im príbuzné systémy

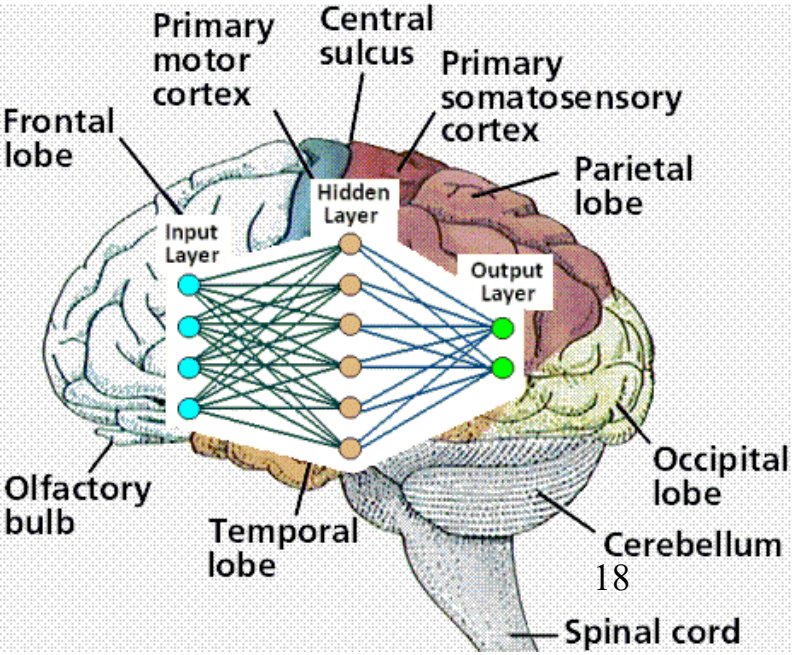

2.2 Stručná história vývoja UNS

- **1.pol. 20. stor. - W.S McCulloch, 1. významná práca o modeli neurónu**
- **40. roky, W.S McCulloch, W.Pits - model neurónu v podstate používaný dodnes**

Mozog, neuróny, synapsie, umelé neuróny

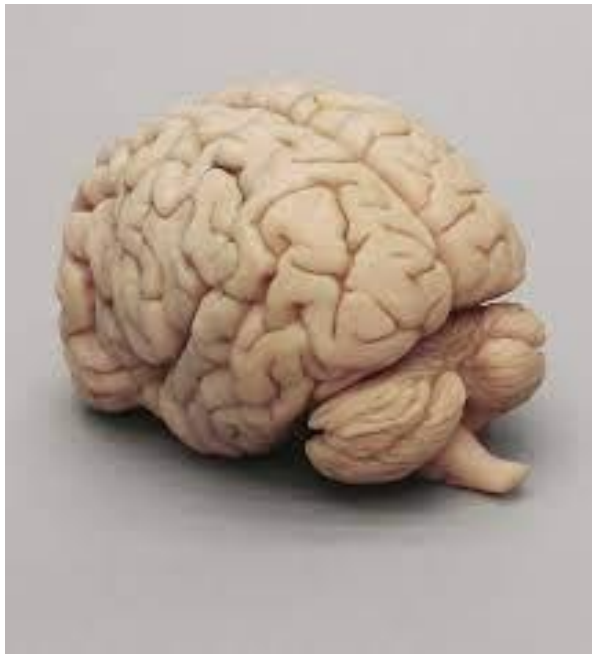

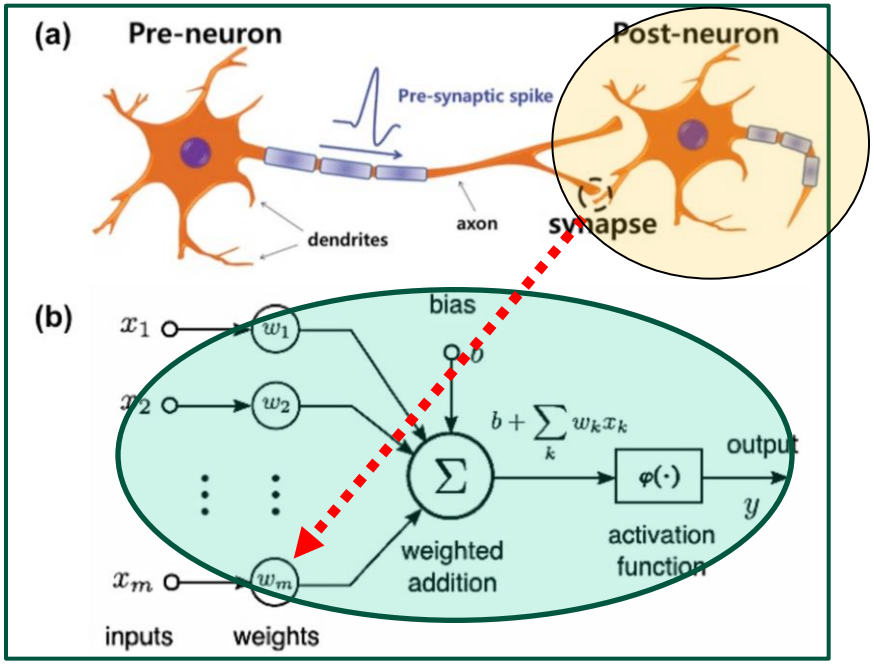

- **Rosenblatt (1958) neurónová sieť – „perceptrón“. Na elektrónkovom počítači naučil sieť neurónov rozpoznávať znaky zachytené na 2D matici foto-senzorov.**

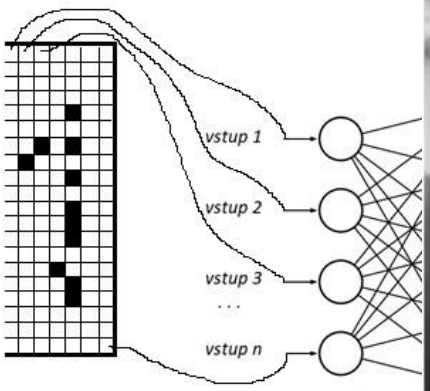

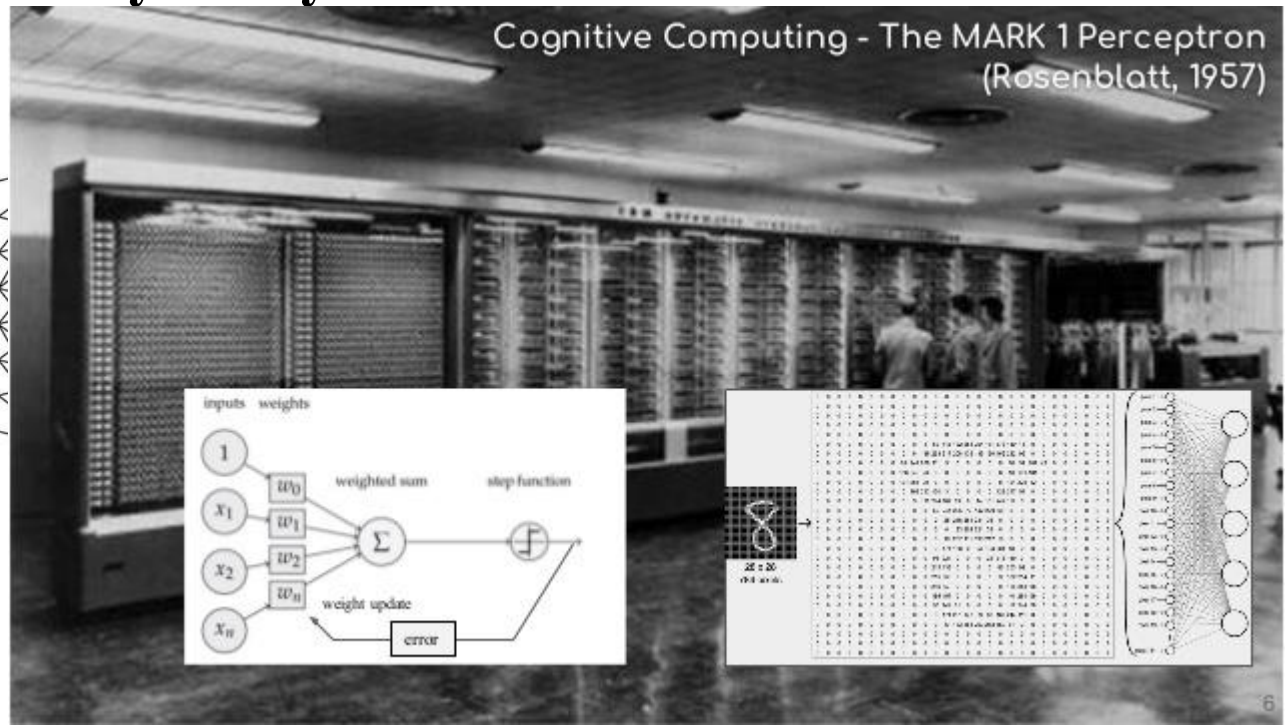

- **Otázky: aké využitie nájdu neurónové siete, ako realizovať zložité transformácie a proces učenia**

• **Minsky a Papert (1969) – „ohraničenosť použitia n.s. iba na lineárne separovateľné problémy“, tento záver <u>zovšeobecnili</u> na všetky typy n.s.**

Lineárne separovateľné a neseparovateľné problémy

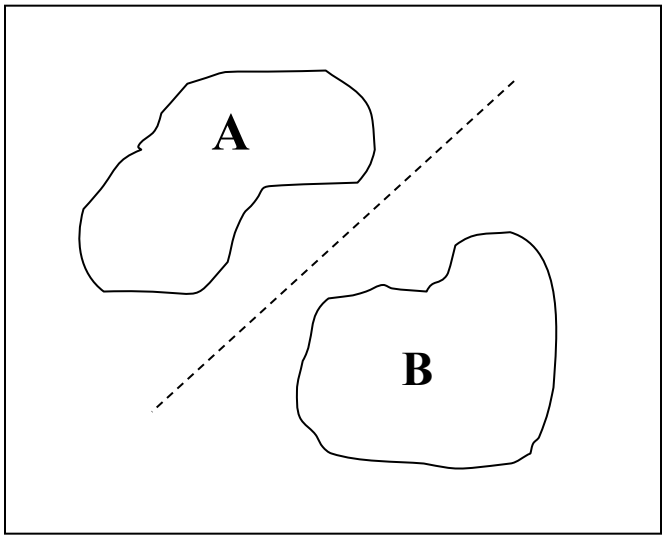

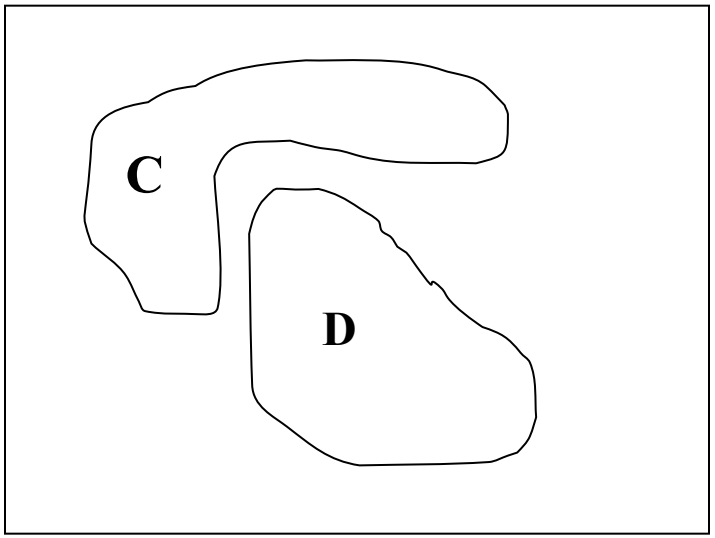

Triedy A a B sú lineárne separovateľné,
triedy C a D nie sú lineárne separovateľné

AND	0	1
0	0	1
1	1	1

AND - lineárne separovateľný problém

XOR	0	1
0	0	1
1	1	0

XOR- lineárne neseparovateľný problém

- **"Ak sa nedá riešiť tento jednoduchý problém (XOR), tak sa nedajú riešiť ani oveľa zložitejšie nelineárne problémy" - Minsky a Papert vplyvom sily svojich osobností *utlmili iniciatívy a záujem* v oblasti vývoja n.s. až do 80. rokov 20. storočia.**
- **Až návrh algoritmu "Error Back-Propagation" (algoritmus spätného šírenia chyby, BP, 1986) priniesol univerzálne riešenie návrhu parametrov viacvrstvových n.s. Toto spôsobilo renesanciu UNS, použitie aj pre riešenie lineárne neseparovateľných problémov.**
- **Dnes sú UNS neodmysliteľnou súčasťou riešenia mnohých problémov: nelineárneho modelovania, klasifikácie, rozpoznávania obrazu, signálov ...**
- **Dnes UNS (hlboké siete, hlboké učenie...) predstavujú hlavný prúd v UI**

2.3 Matematický (počítačový) neurón

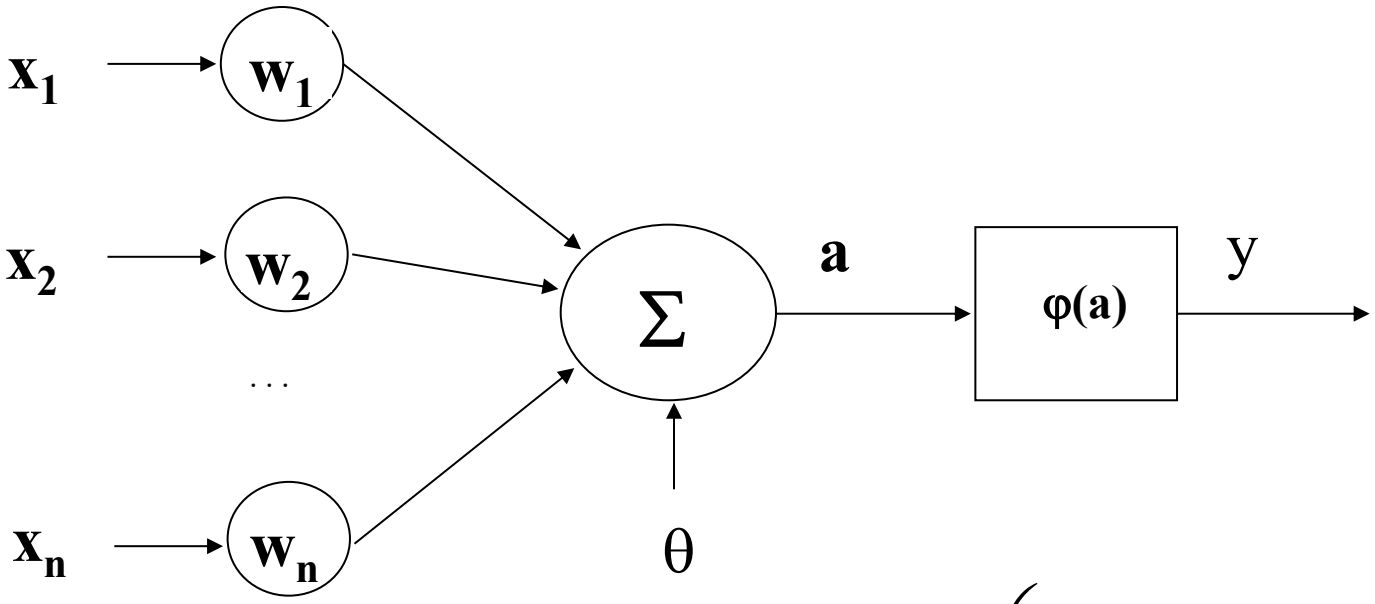

$$y = \varphi\left(\sum_{i=1}^{n}(w_i x_i) - \theta\right) = \varphi(a)$$

x_i - vstupy neurónu

w_i - váhy synaptických spojení

θ - prah (citlivosti) neurónu

a - vnútorná aktivita neurónu

φ - aktivačná funkcia neurónu

y - výstup neurónu

Aktivačné funkcie neurónov

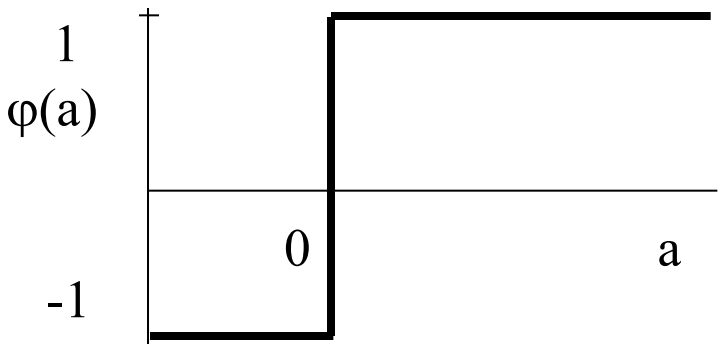

$\varphi(a) = -1$ pre $a<0$
$\varphi(a) = 1$ pre $a>=0$

skoková funkcia < -1; 1 >

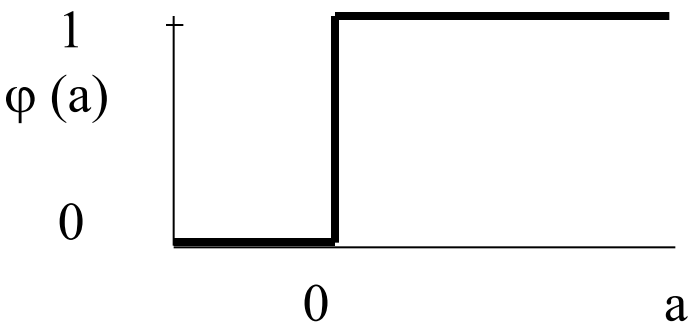

$\varphi(a) = 0$ pre $a<0$
$\varphi(a) = 1$ pre $a >=0$

skoková funkcia <0; 1 >

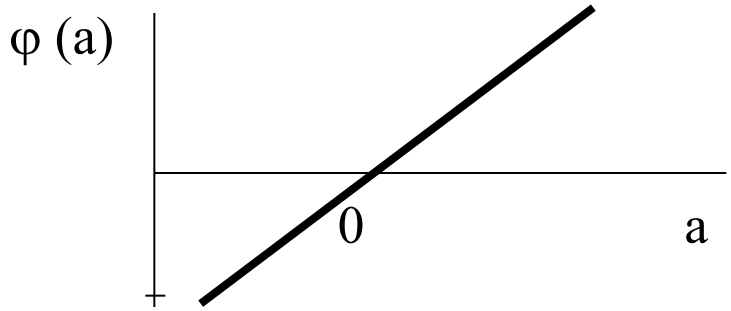

$\varphi(a) = a$

lineárna funkcia

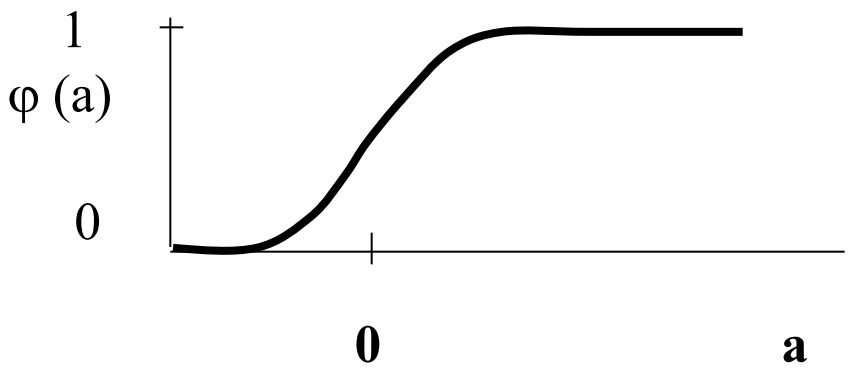

$$\varphi(a) = \frac{1}{1 + e^{-\beta a}}$$

sigmoida - logistická f.

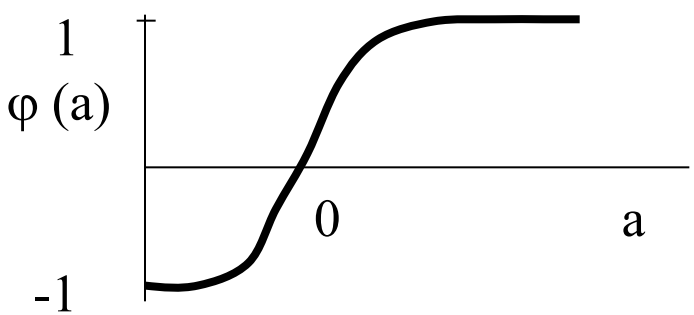

$$\varphi(a) = tgh(a/2) = \frac{1 - e^{-a}}{1 + e^{-a}}$$

hyperbolický tangens

Umelá neurónová sieť (UNS)

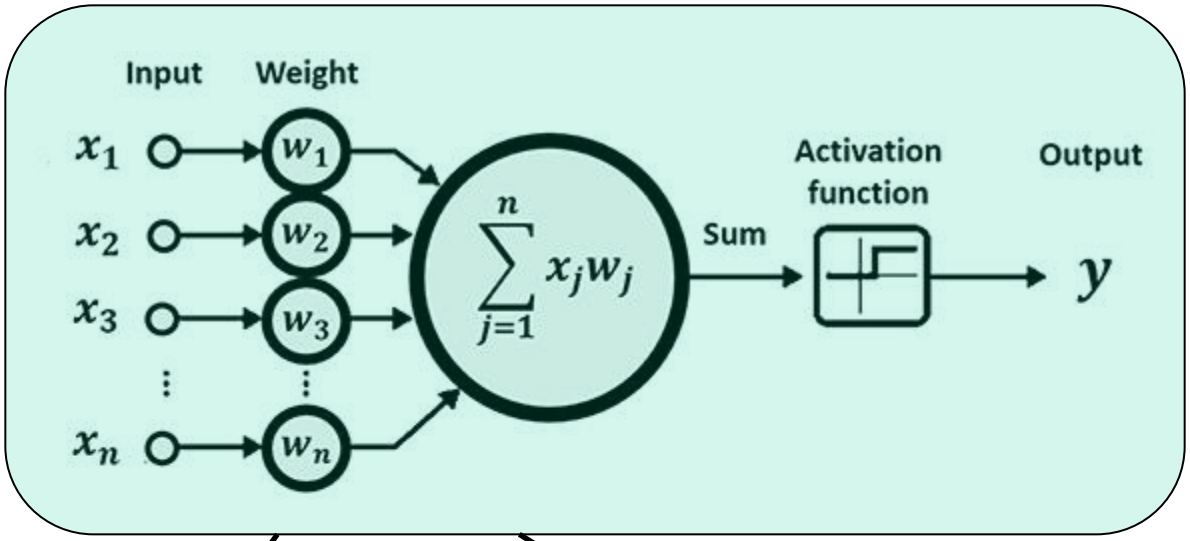

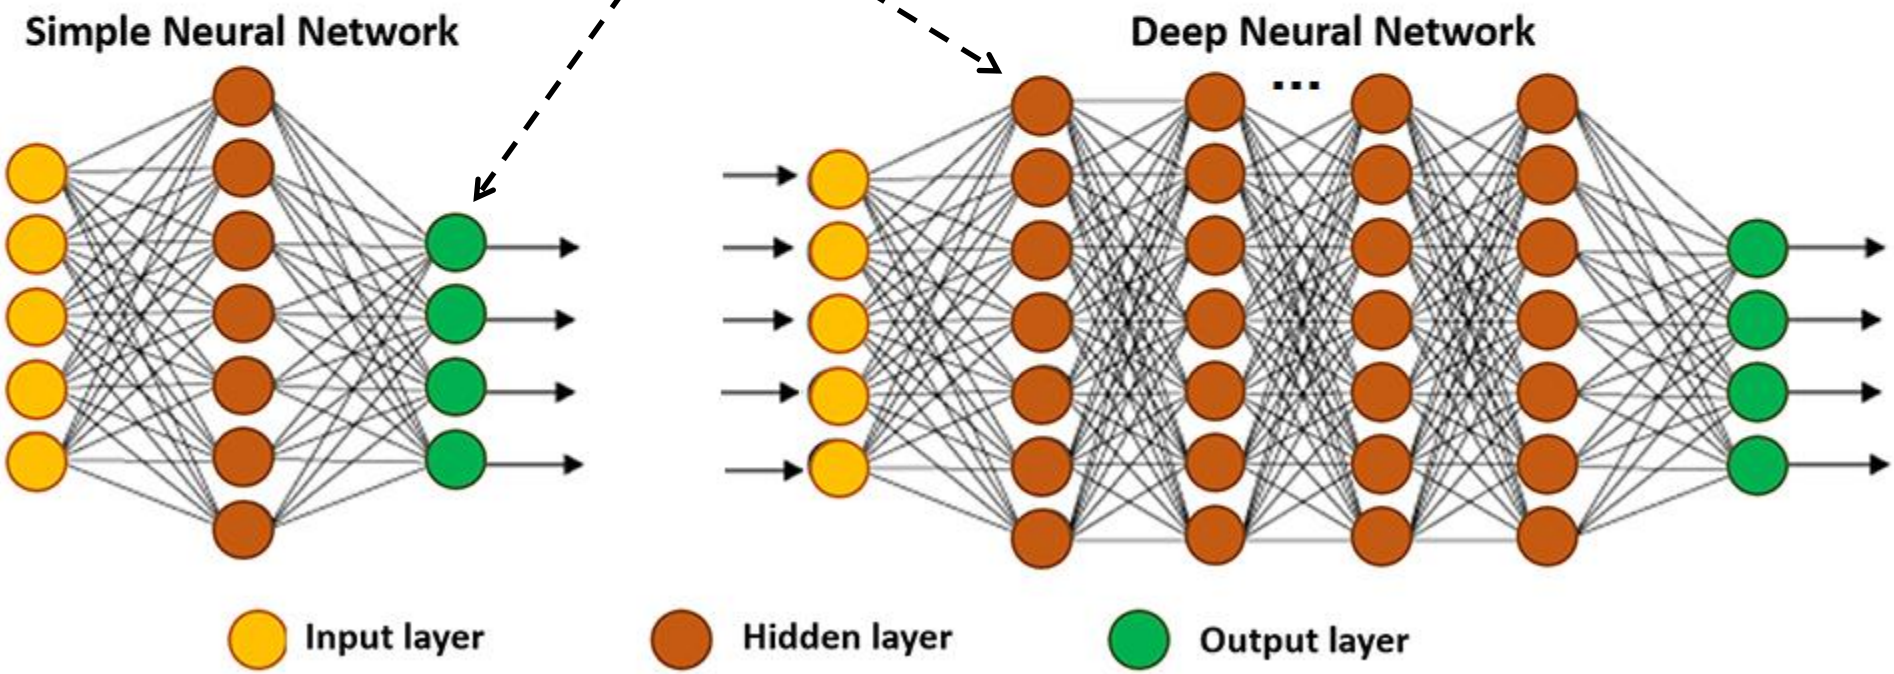

2.4 Rozdelenie neurónových sietí podľa architektúry

a) Vrstvové štruktúry

Jednovrstvové (resp. dvojvrstvové) siete

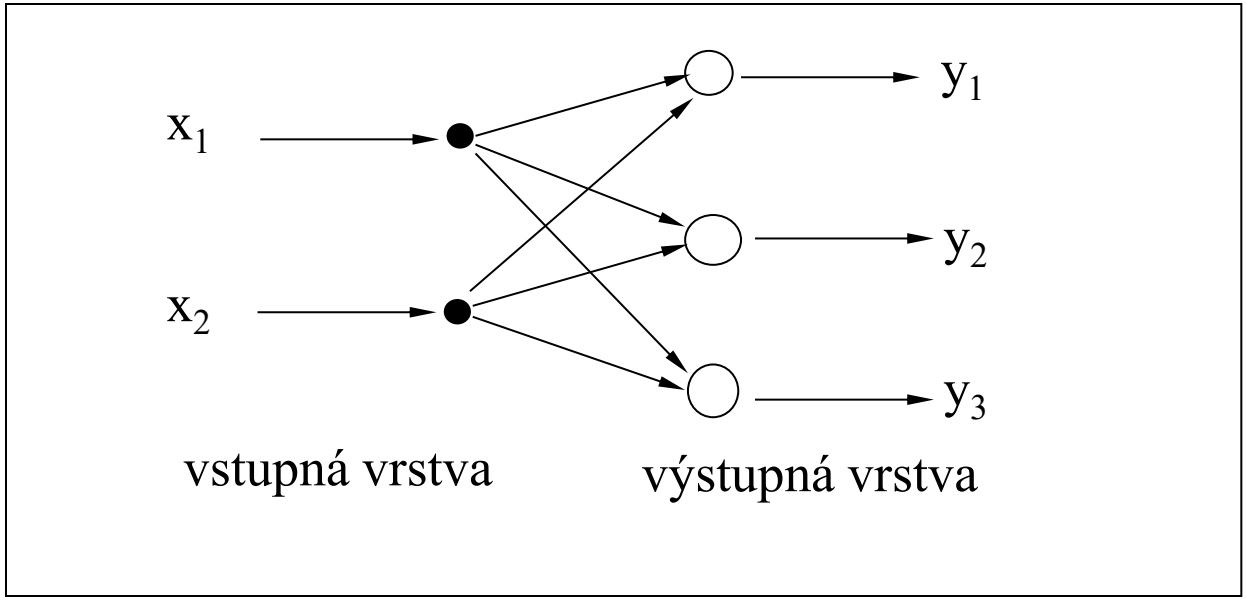

(napr. sieť štruktúry 2-3) úplné prepojenie, obyčajne - perceptrónové siete so skokovými aktivačnými funkciami za účelom klasifikácie do tried (iba lin. separovateľné problémy)

Viacvrstvové siete

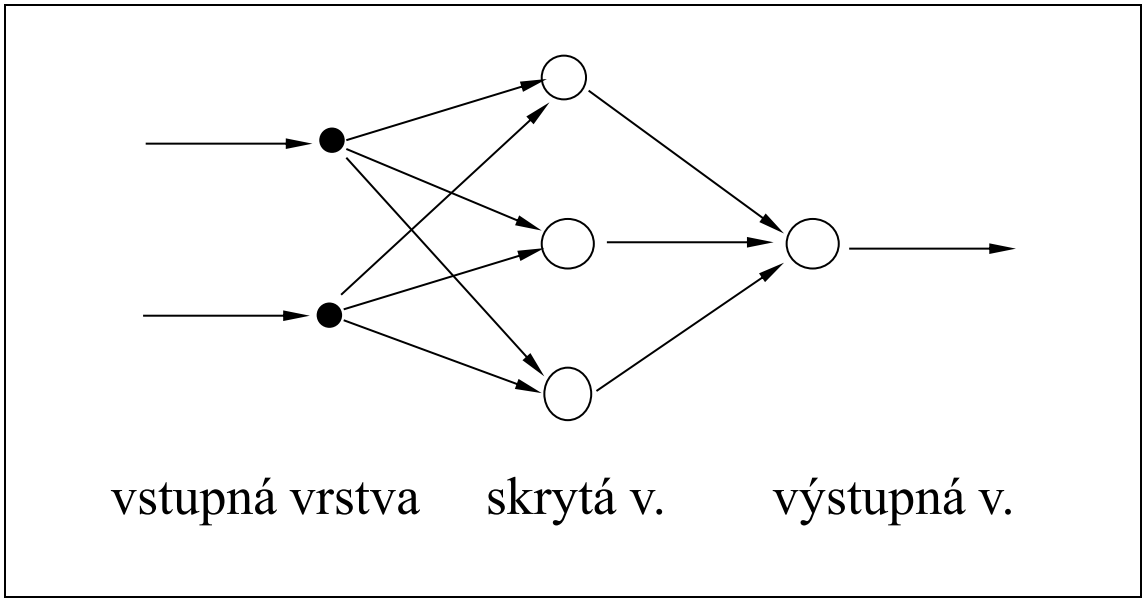

Viacvrstvové siete obsahujú aspoň jednu skrytú vrstvu. Na obr. je trojvrstvová sieť štruktúry 2-3-1. Vstupná vrstva iba distribuuje vstupné signály, výkonnú funkciu majú len skrytá a výstupná vrstva.

Viacvrstvové siete

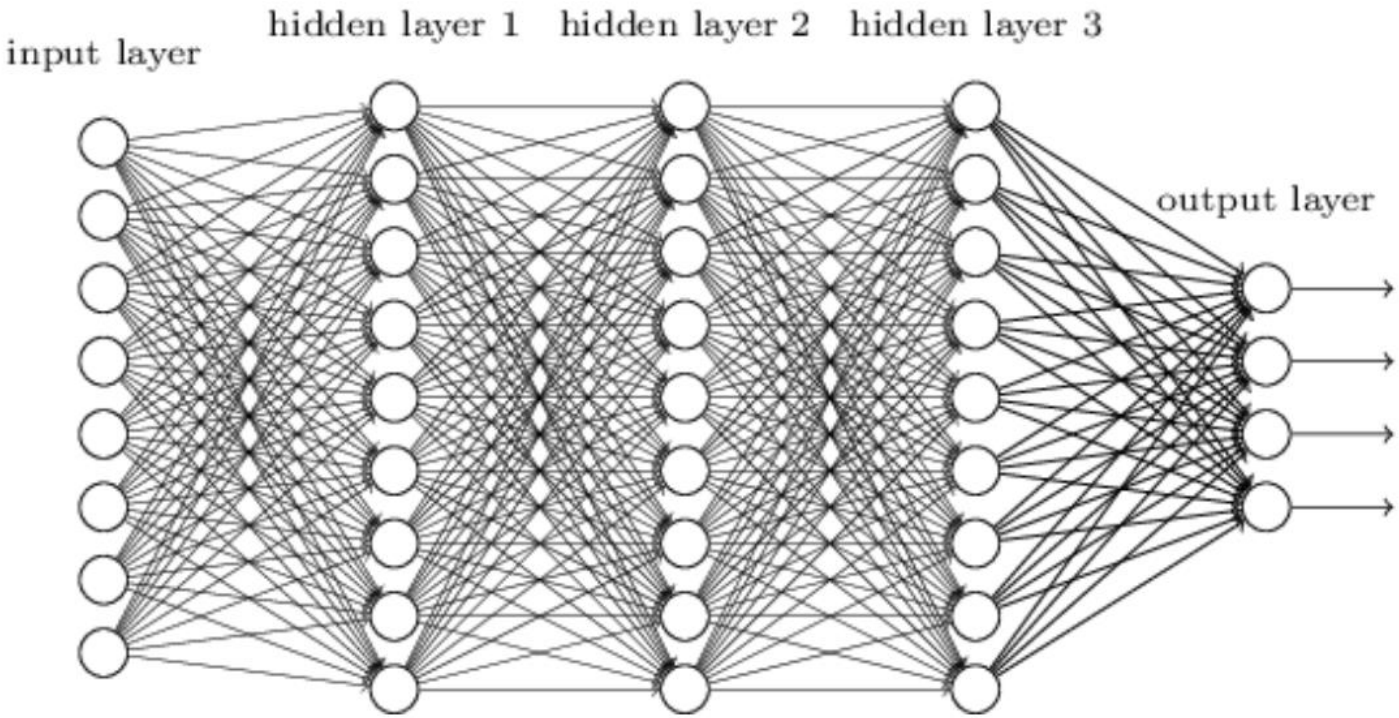

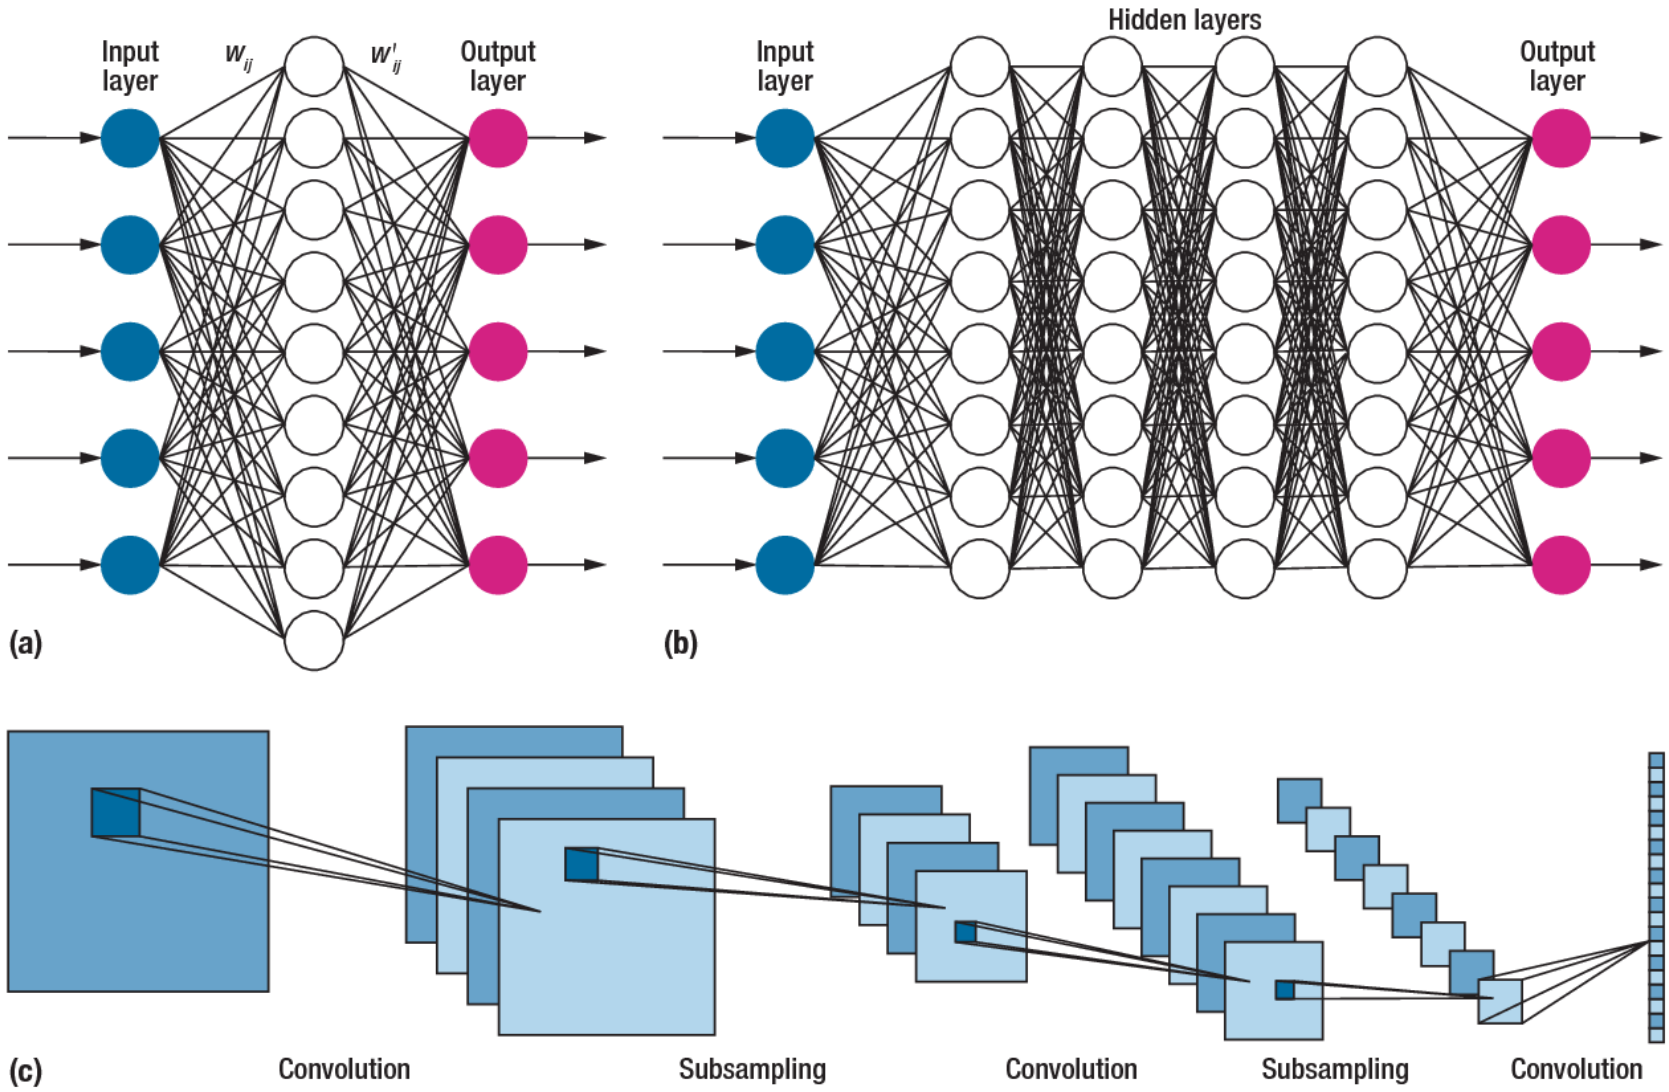

Hlboké siete (Deep NN)

Príklad parametrizovanej UNS

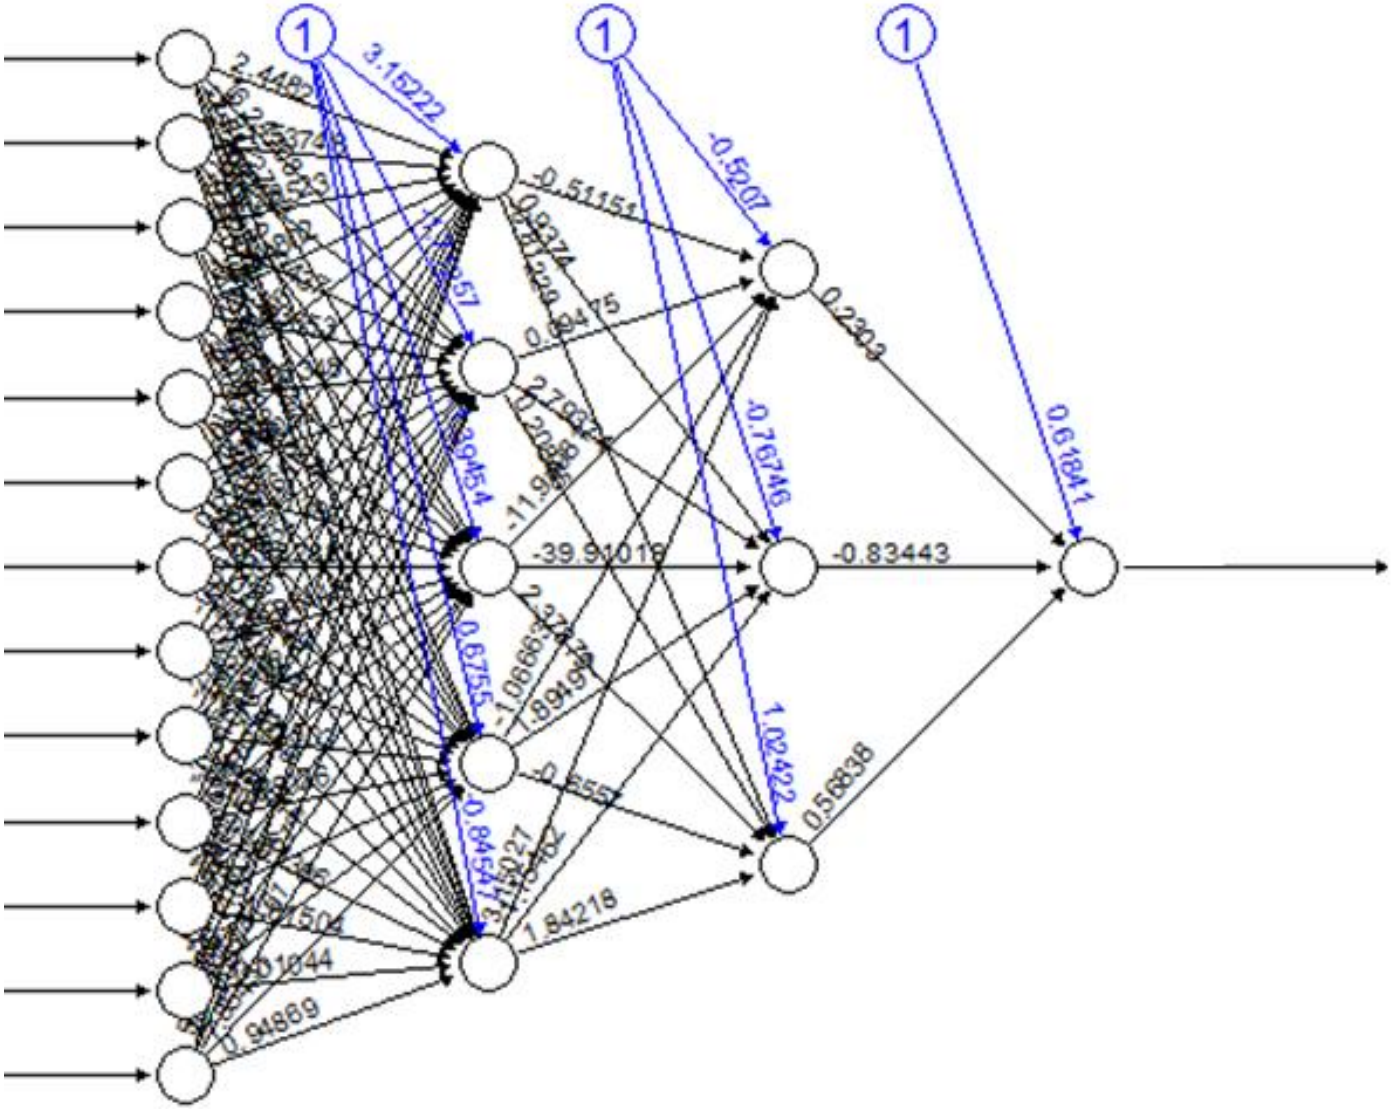

b) Dopredné a rekurentné vrstvové štruktúry

Dopredné siete

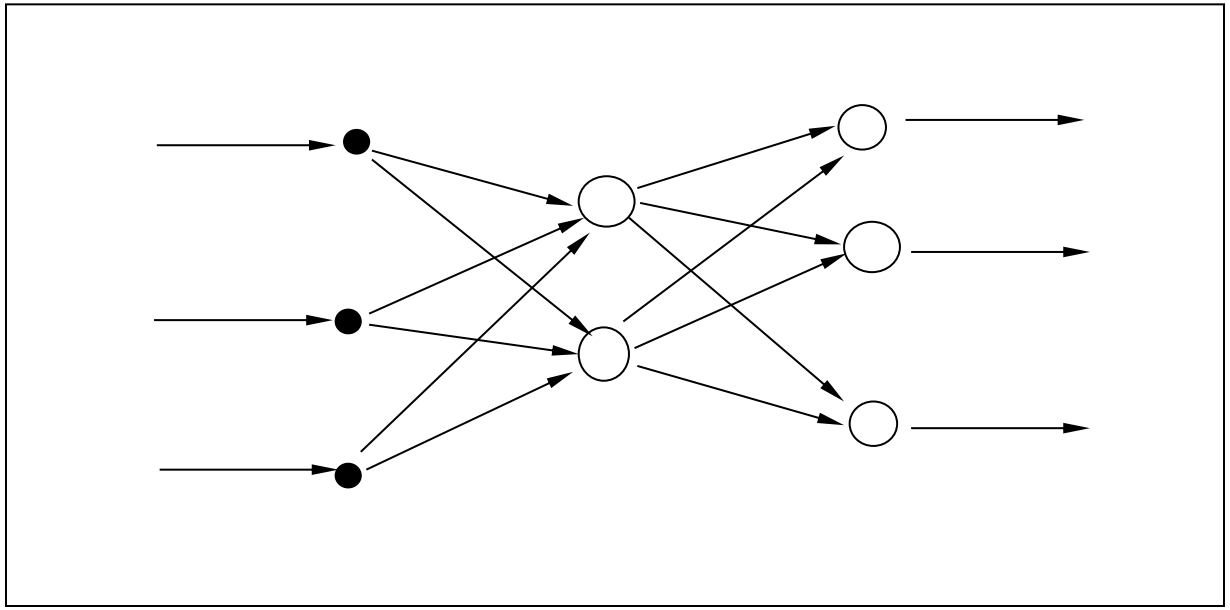

Dopredné siete obsahujú iba väzby v smere od vstupov k výstupom. Na obr. je dopredná sieť veľkosti 3-2-3.

Rekurentné siete

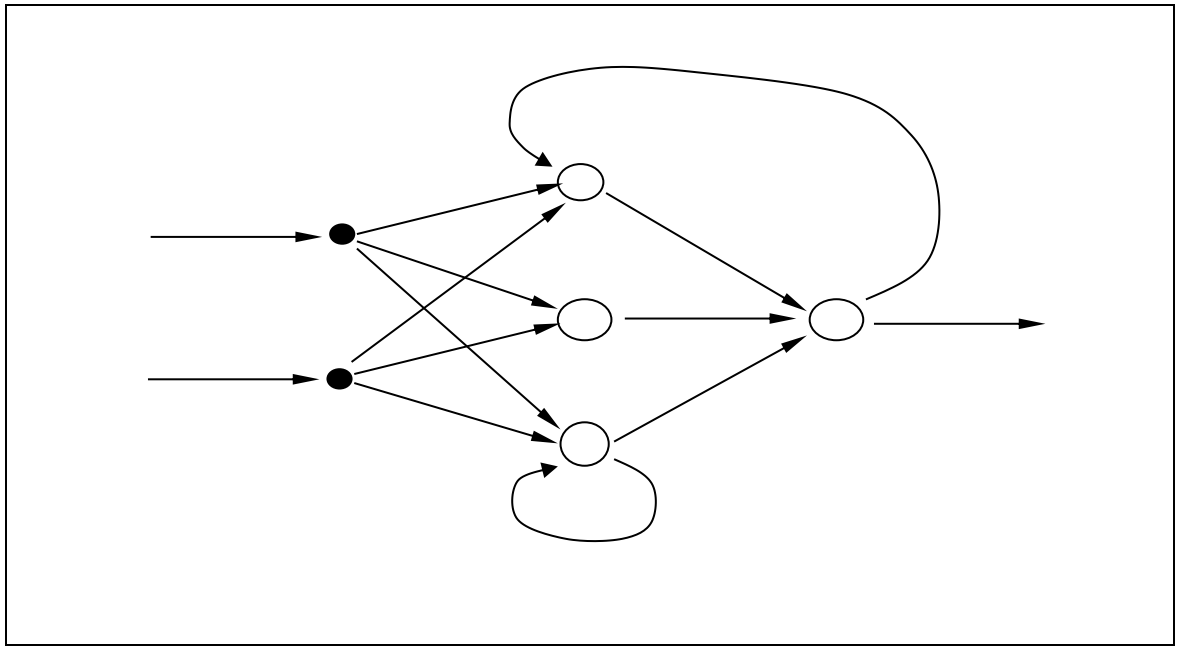

Rekurentné siete sú podobné ako dopredné, ale obsahujú aspoň jednu spätnú väzbu v rámci tej istej vrstvy alebo v rámci rôznych vrstiev.

c) Iné štruktúry sietí

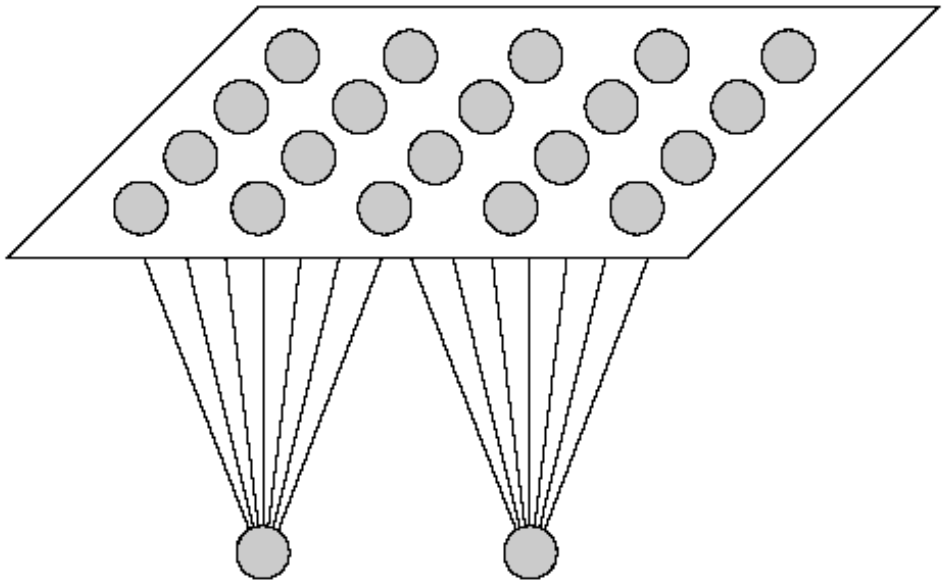

Mriežková štruktúra siete (Kohonenova sieť)

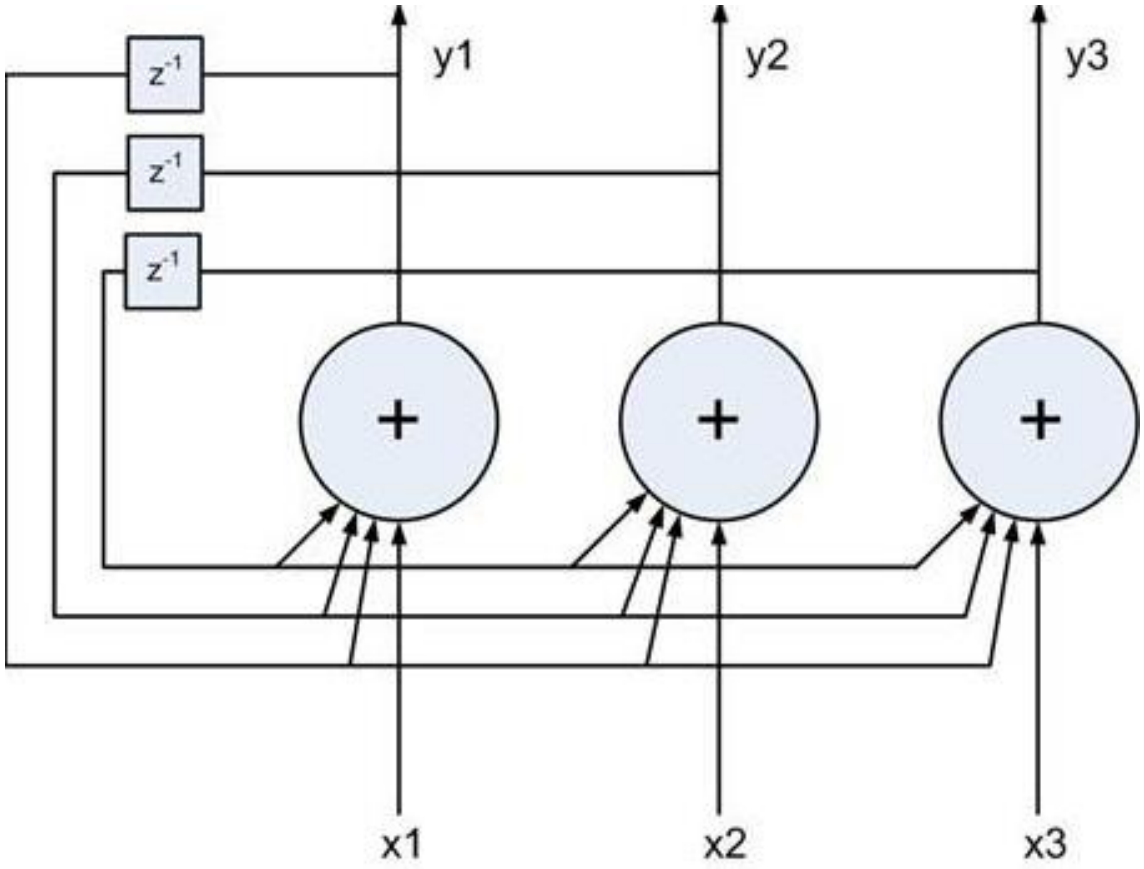

Hopfieldova sieť

a iné ...

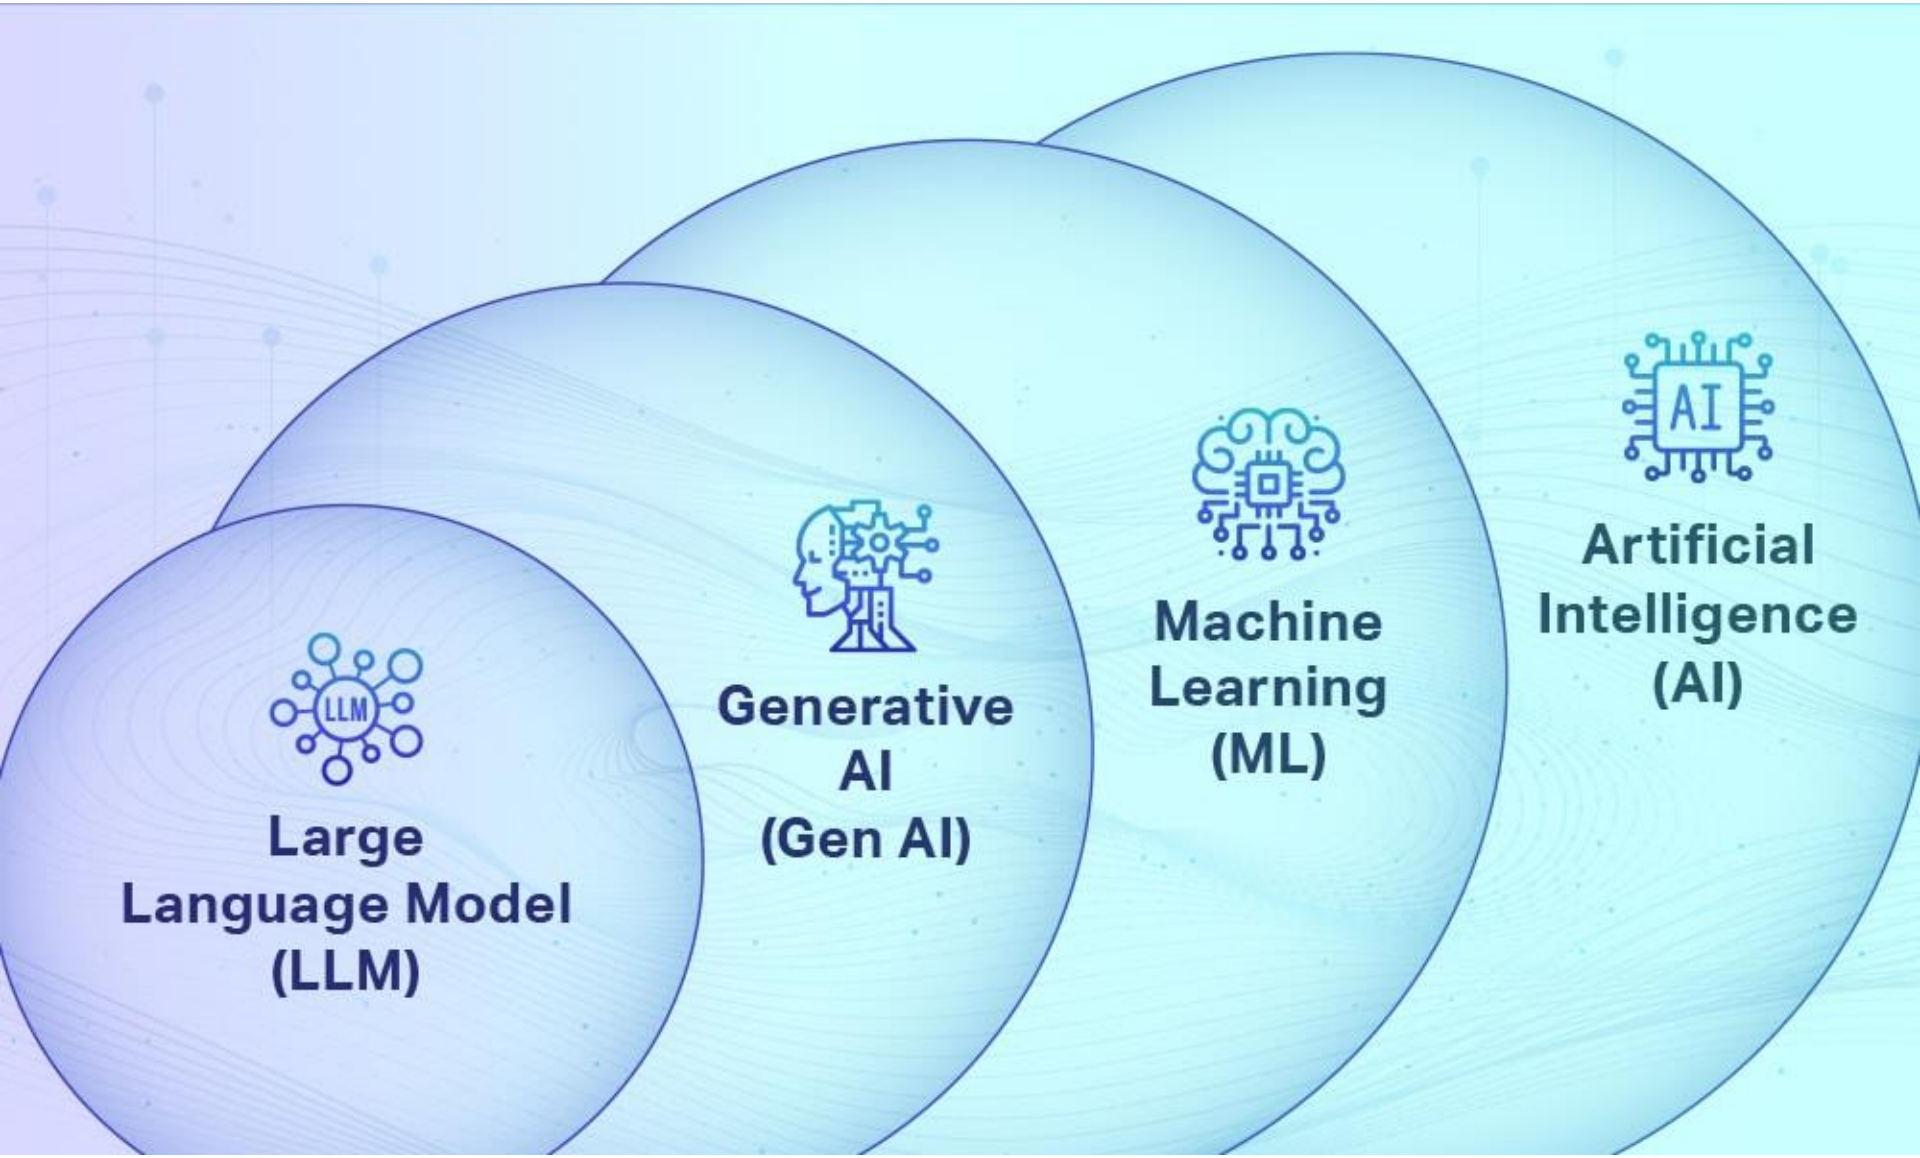

Veľké jazykové modely

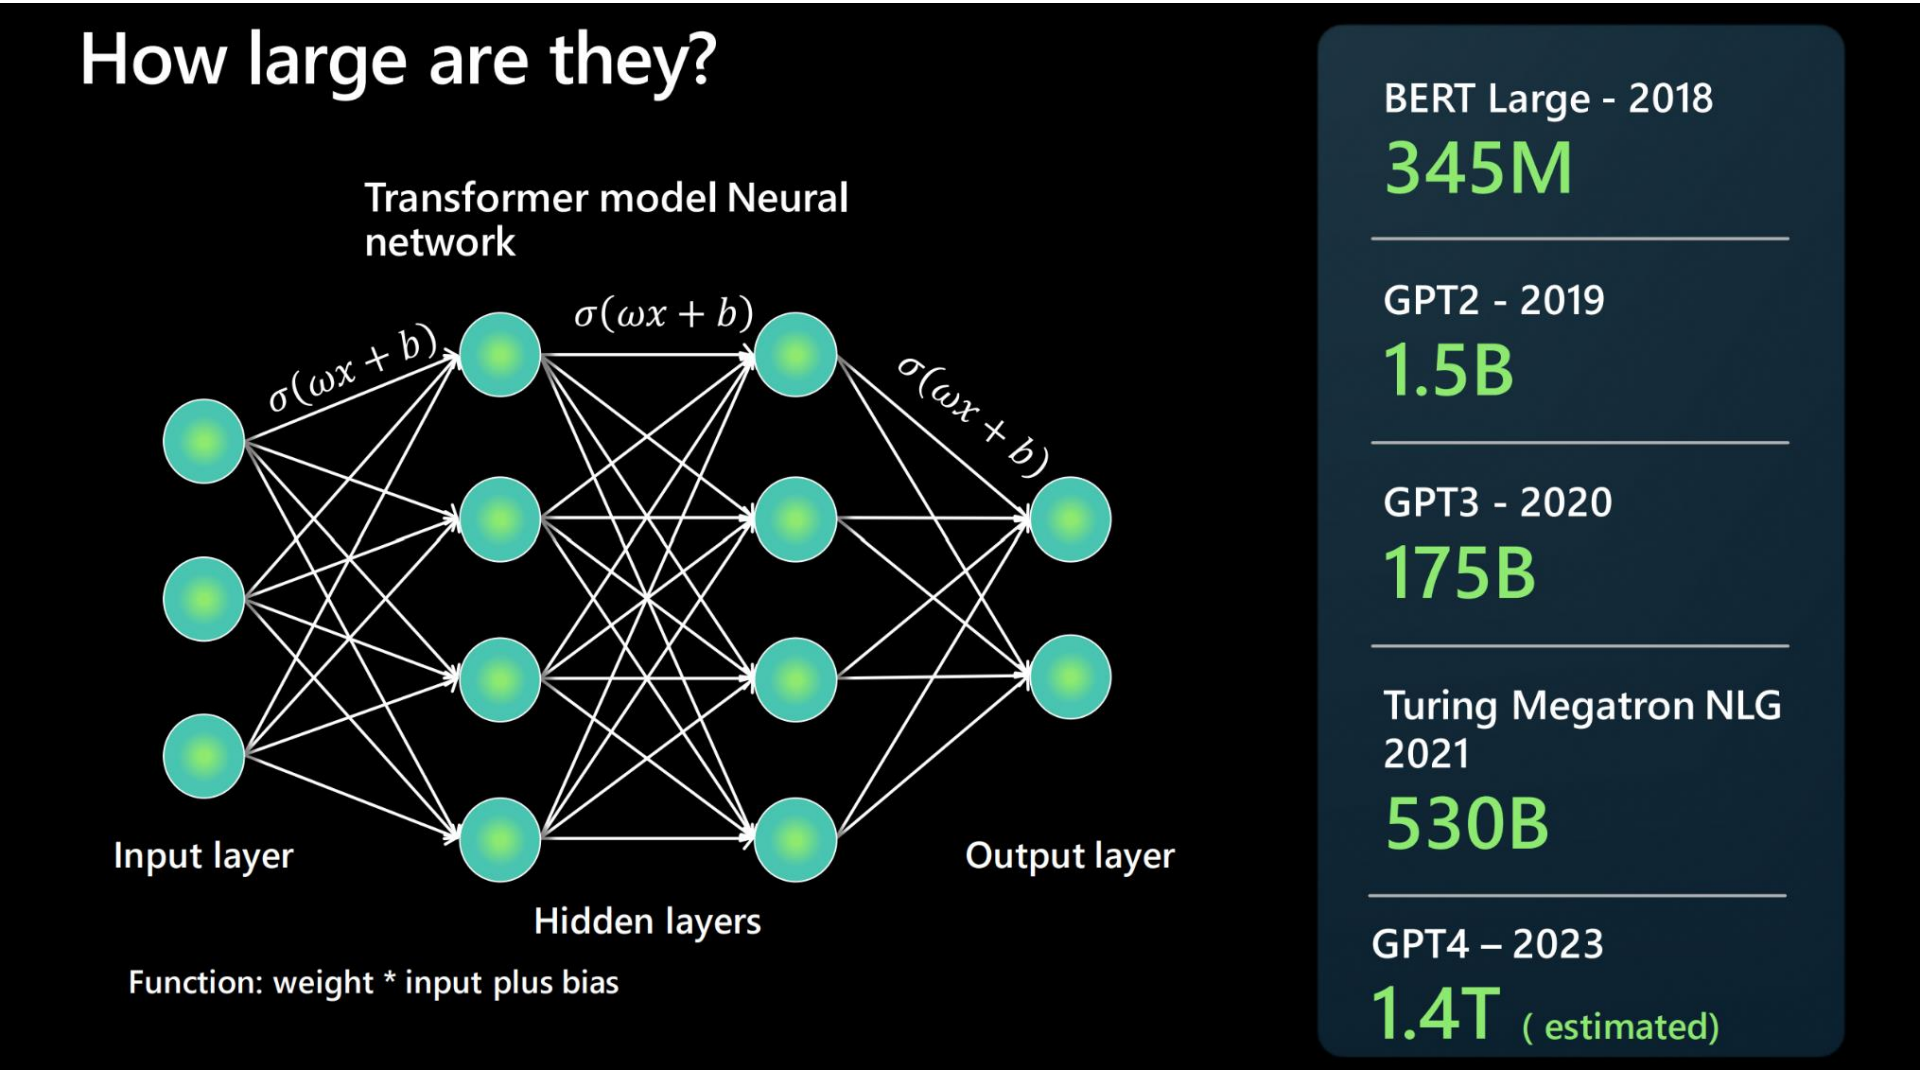

Veľké jazykové modely – počet váh (trenovateľných parametrov)

T=10e12 (Bilión)

Mozog človeka = 150 Bilónov synapsií (váh, TP)

2.5 Strojové učenie
Učenie UNS

Učenie s učiteľom (Supervised learning)

Klasifikácia, regresia, aproximácia

Regresné modely,
Rozhodovacie stromy
Podporné vektorové stroje (SVM)
Umelé neurónové siete,
Hlboké siete (Deep networks)

Sú k dispozícii vstupy aj očakávané výstupy (tzv. označené dáta). Cieľom je naučiť model predikovať nový výstup na základe nových vstupov.

Učenie bez učiteľa (Unsupervised learning)

Zhlukovanie (clustering), predikcia, asociácia

K-means
Hierarchické zhlukovanie
Asociačné pravidlá
Umelé neurónové siete ...

Neoznačené dáta, cieľom je objaviť vzory, štruktúry, závislosti, skryté súvislosti v dátach bez konkrétneho výstupu.

Učenie na základe interakcie s prostredím

Rozhodovanie, riadenie

Učenie s odmenou a trestom (Reinforcement learning)
Neuro-evolúcia
Umelé neurónové siete,
Hlboké siete (Deep networks)

Agent interaguje s prostredím (modelom) a učí sa na základe spätných väzieb vo forme odmien alebo trestov alebo využitím simulovanej evolúcie.

1. Učenie s učiteľom (Supervised Learning)

1. zber vstupno/výstupných dát

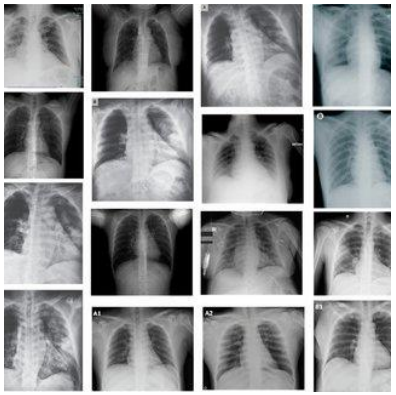

Realita /prostredie

snímky → diagnózy

Vstupné dáta

Výstupné dáta (označenia človekom)

Vstupno/výstupné dáta (trénovacie dáta)

Učenie s učiteľom
2. trénovanie (učenie) modelu

Vstu
p

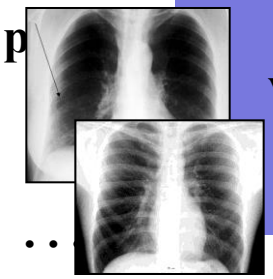

. .

vstupno/výstupné dáta

Výstupy

+

chyba

-

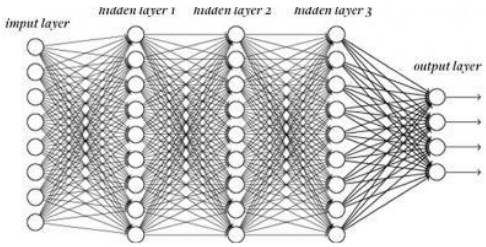

model: umelá neurónová sieť (UNS)

Algorit-mus učenia

Učenie s učiteľom
3. použitie modelu

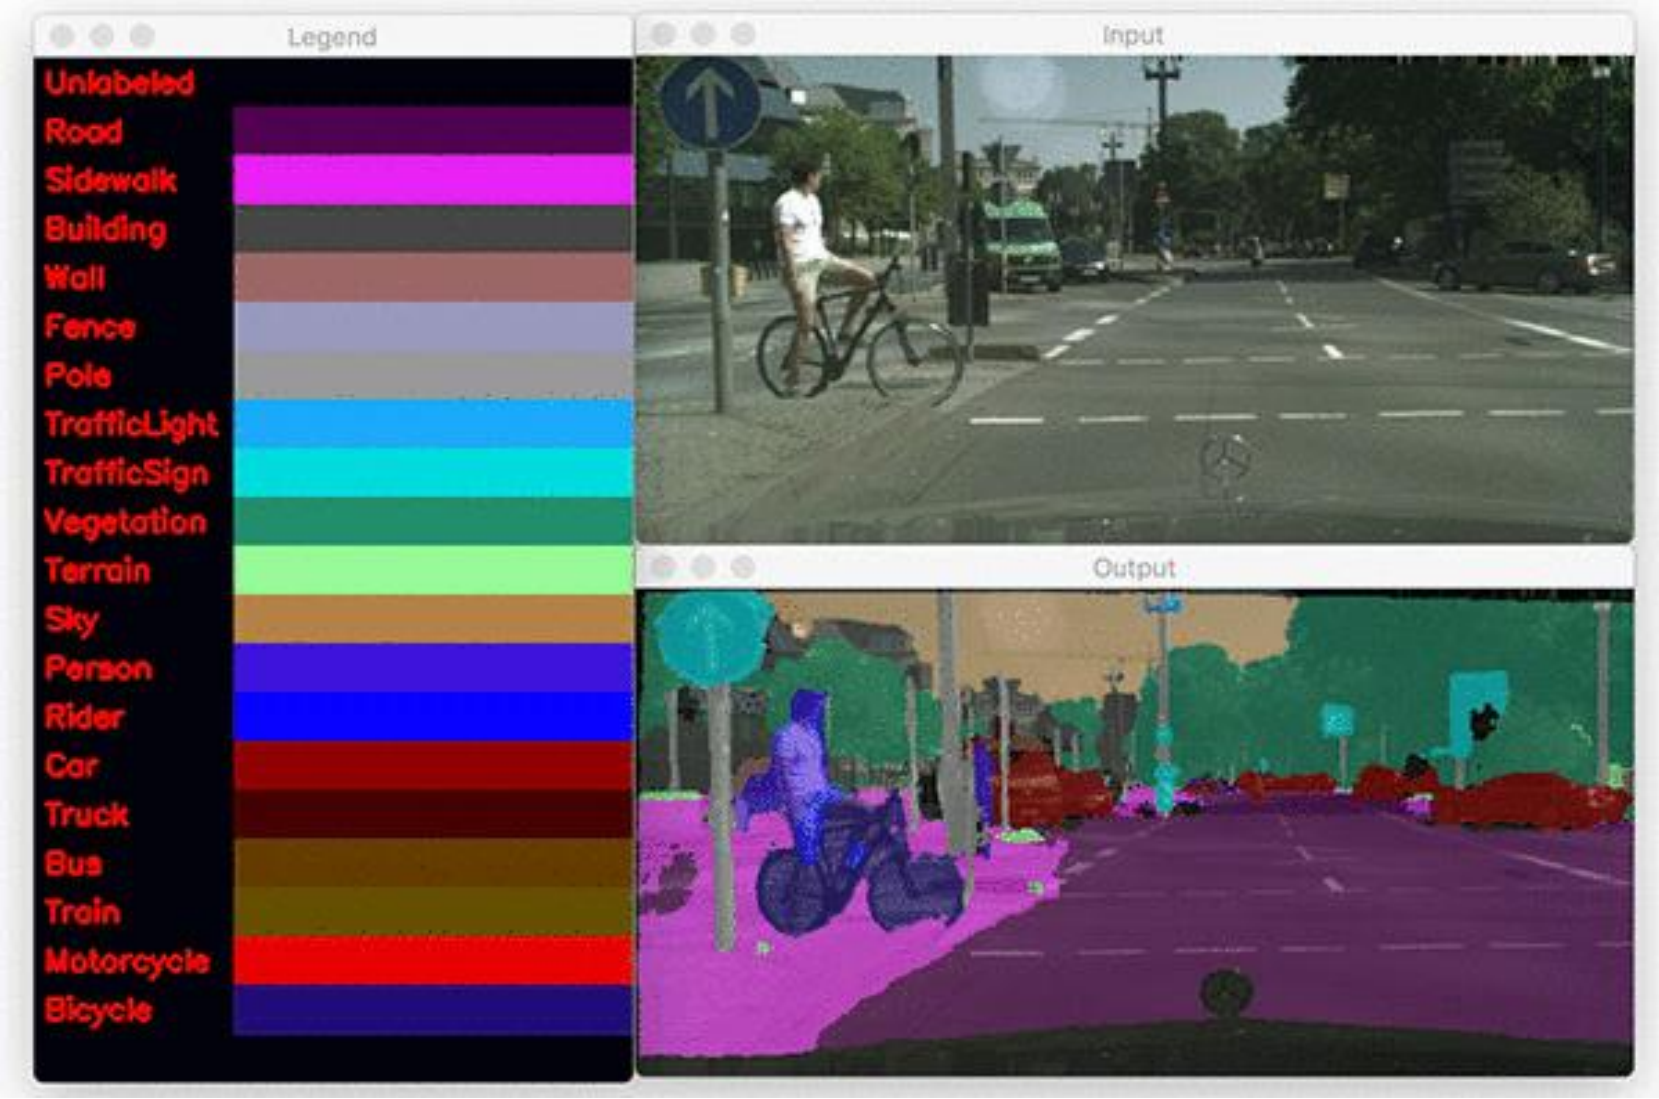

Naučená sémantická segmentácia scény

UNS sa naučí „poznať“ entity na základe vzorových príkladov.

2. Učenie bez učiteľa (Unsupervised Learning)

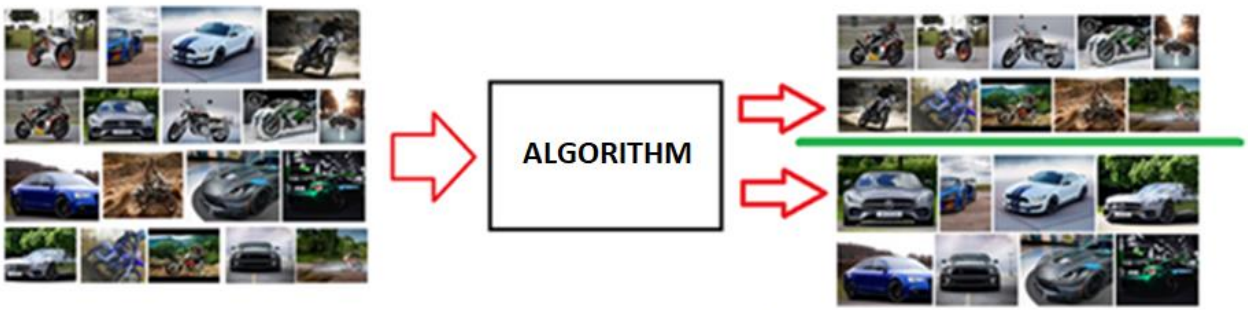

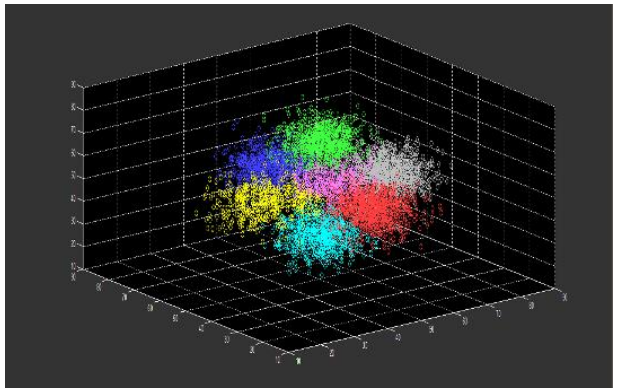

UNS sama pochopí „skryté“ súvislosti medzi objektami, javmi, dátami...

3. Učenie so spätnou väzbou (bez učiteľa) (na základe interakcie s prostredím)

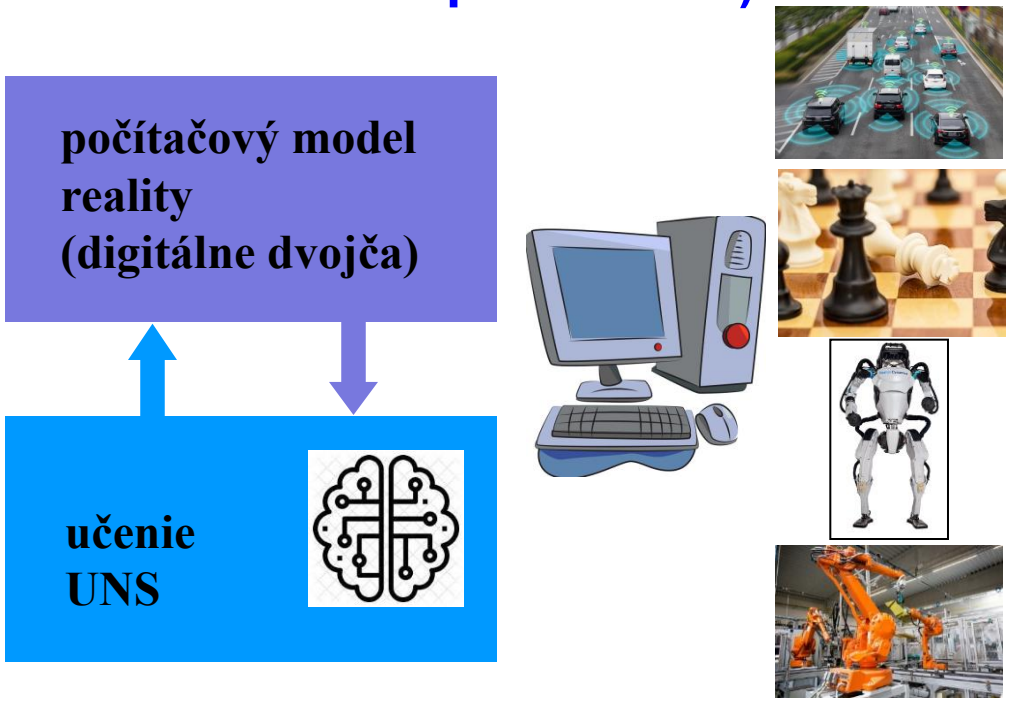

Riadenie, autonómne systémy, hry, riešenie problémov ...

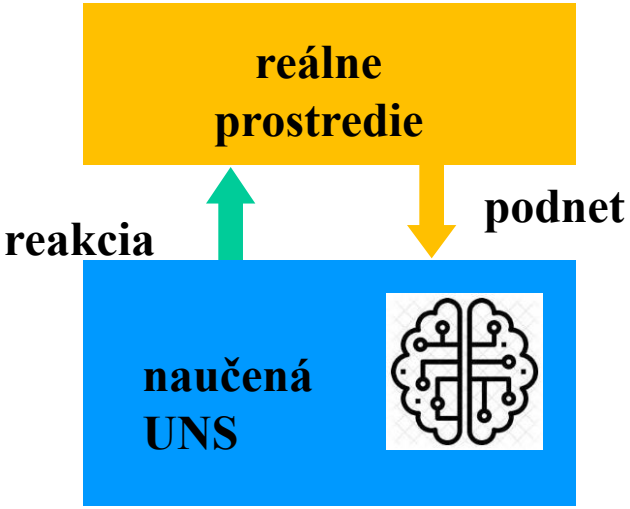

- **Učenie s posiľňovaním (Reinforcement Learning)**
- **Neuro-evolúcia**
- **...**

UNS sa naučí interagovať s realitou na základe tréningu na modeloch reality.

Posilňované učenie (Reinforcement Learning, RL)

Tu nepoužívame žiadnu predpripravenú množinu trénovacích dát, či už so správnymi odpoveďami alebo bez. Vytvoríme mechanizmus, ktorý sa v prostredí sám učí. Musíme určiť pravidlá správania sa prostredia (model prostredia) a ohodnocovací systém (kriteriálnu funkciu). Čiže musíme ohodnotiť, či nám aktuálne správanie vyhovuje alebo nie, v lepšom prípade vieme aj jemnejšie ohodnotiť, do akej miery nám vyhovuje. Následne nejakou metódou, napríklad pokus-omyl, skúšame rôzne možnosti alebo modifikujeme aktuálne riešenie a snažíme sa čo najlepšie prispôsobiť podmienkam prostredia.

Príkladom posilňovaného učenia môže byť tvorba umelého hráča hry Dáma, Šach alebo Go. Určíme pravidlá hry, ktoré sa musia dodržiavať a spôsob odmeňovania za úspešné akcie, za vyhodené figúry či za výhru. Potom necháme počítač hrať hru, napríklad samého proti sebe, veľmi veľa krát, až dosiahneme vysoký stupeň majstrovstva. Dokonca taký, ktorý je nedosiahnuteľný človekom.

Neuro-evolúcia

Podobné ako posiľňované učenie, ale na hľadanie riešenia (parametrov UNS) prostredníctvom minimalizácie kriteriálnej funkcie sa využíva evolučný algoritmus.

Učenie mobilného robota pomocou neuro-evolúcie pohybovať sa v prostredí z A do B. Minimalizuj dráhu a kolízie s prostredím.

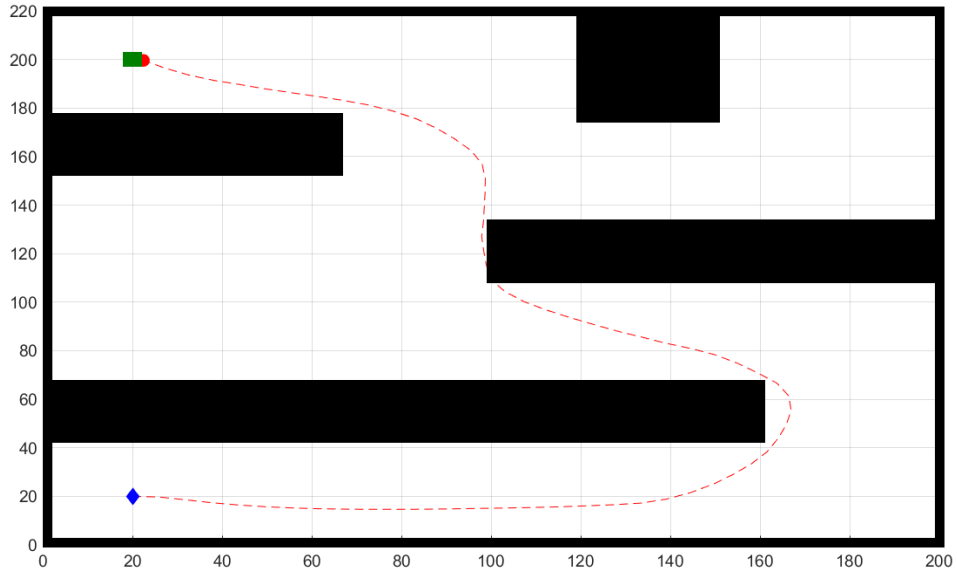

Vybrané typy sietí, spôsoby ich učenia (trénovania) a ich použite

2.6 Jednovrstvové perceptrónové siete

Tieto siete sa tiež nazývajú "perceptrón". Predstavujú ich neuróny so skokovou aktivačnou funkciou usporiadané do jednej vrstvy.

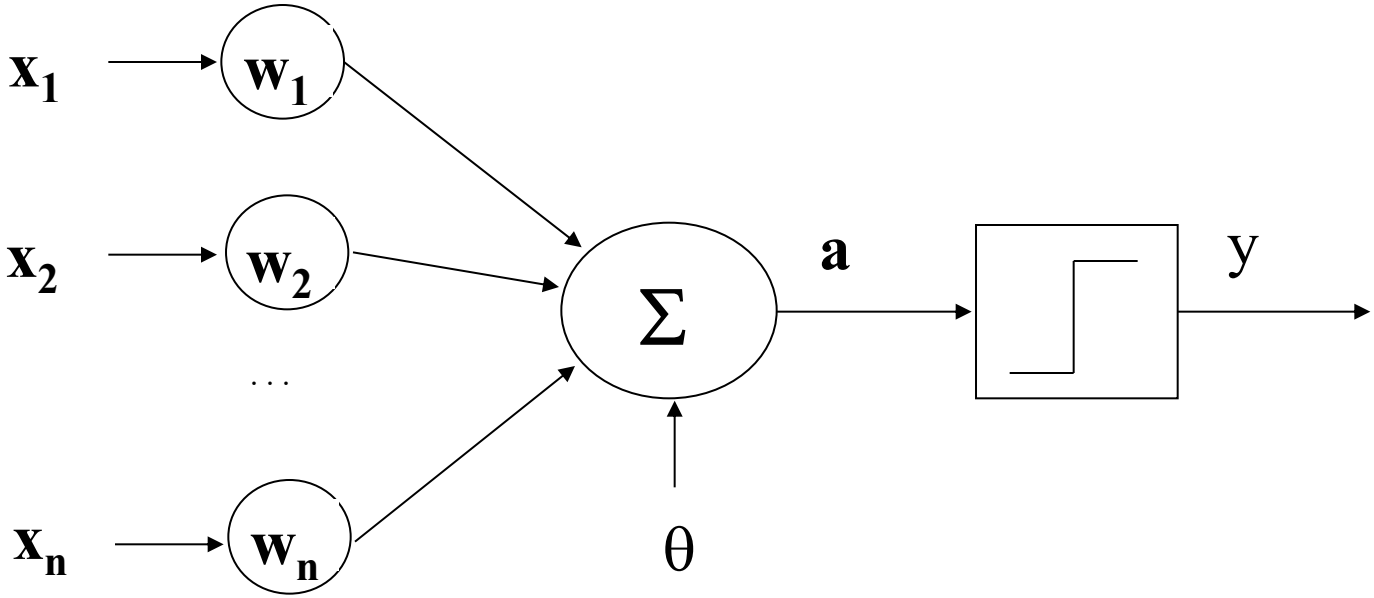

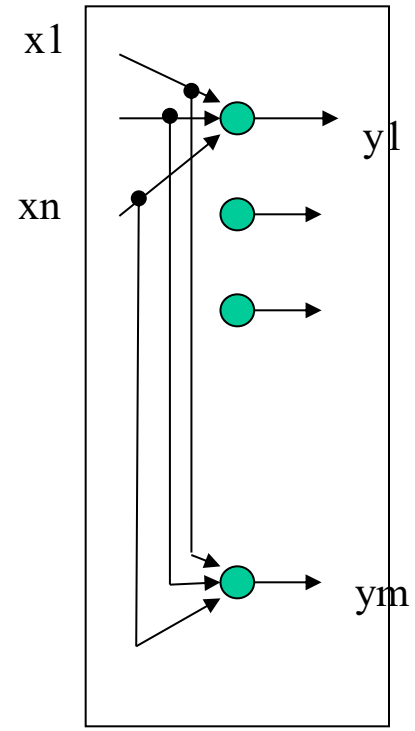

Táto sieť dokáže iba klasifikovať (kódovať) vstupné objekty (vzorky, vektory) - priraďovať ich do tried. Ak výstup i-teho neurónu y_i je 1, potom vstupný objekt, charakterizovaný vektorom x_i patrí do triedy C_i. Ak výstup je rovný 0 (alebo -1) , potom do tejto triedy nepatrí.

Klasifikácia objektov do tried

Klasifikácia objektov - triedenie ovocia

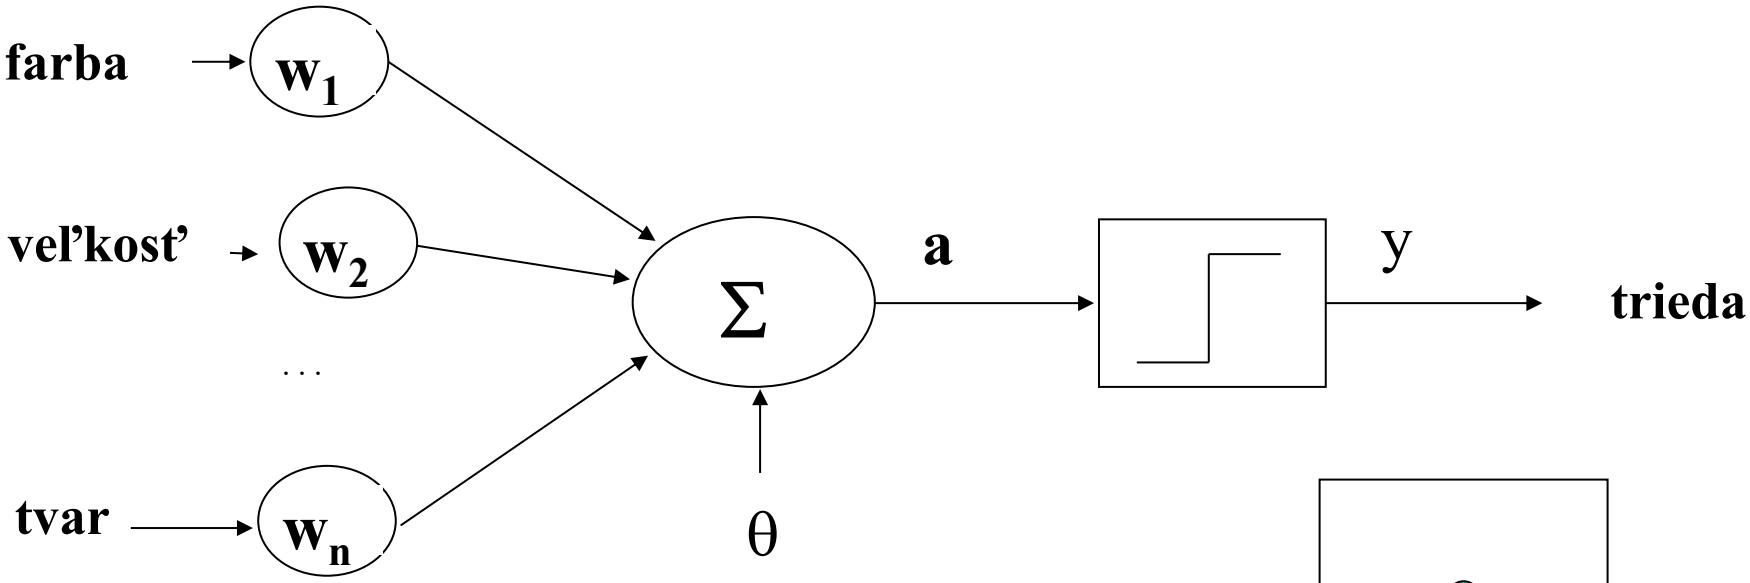

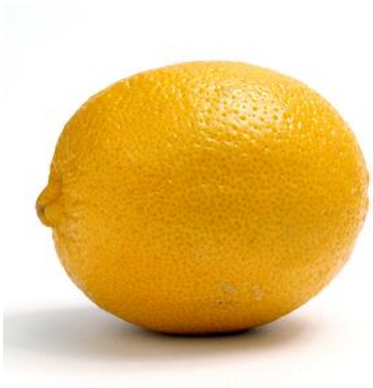

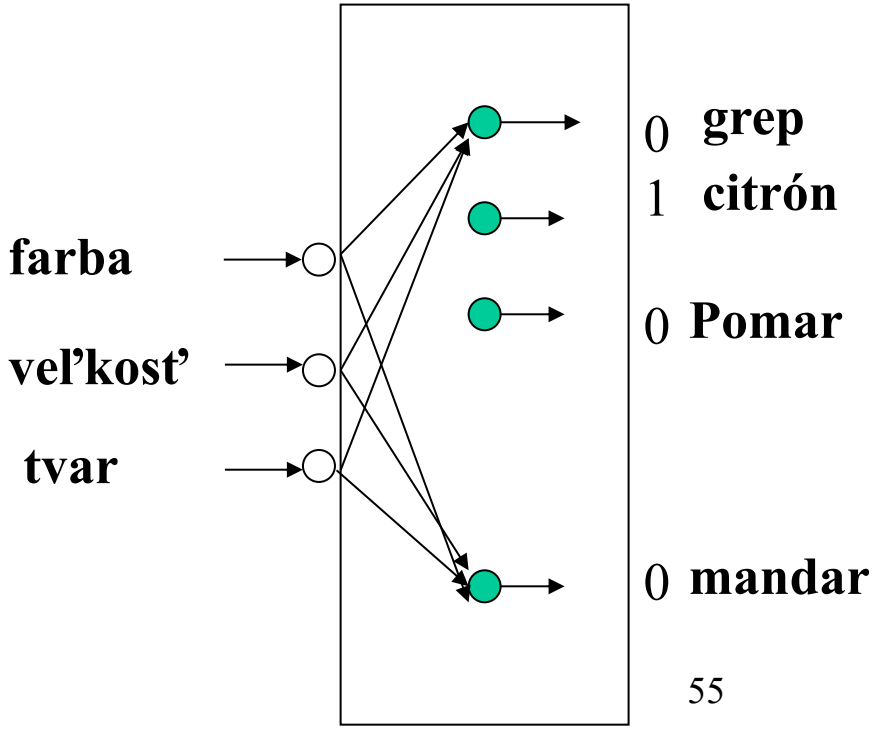

Príklad ***učenia 1-vrstvového perceptrónu***

Úloha: ***modelovanie logickej funkcie AND***
Model: ***1neurón, 2 vstupy / 1 výstup***

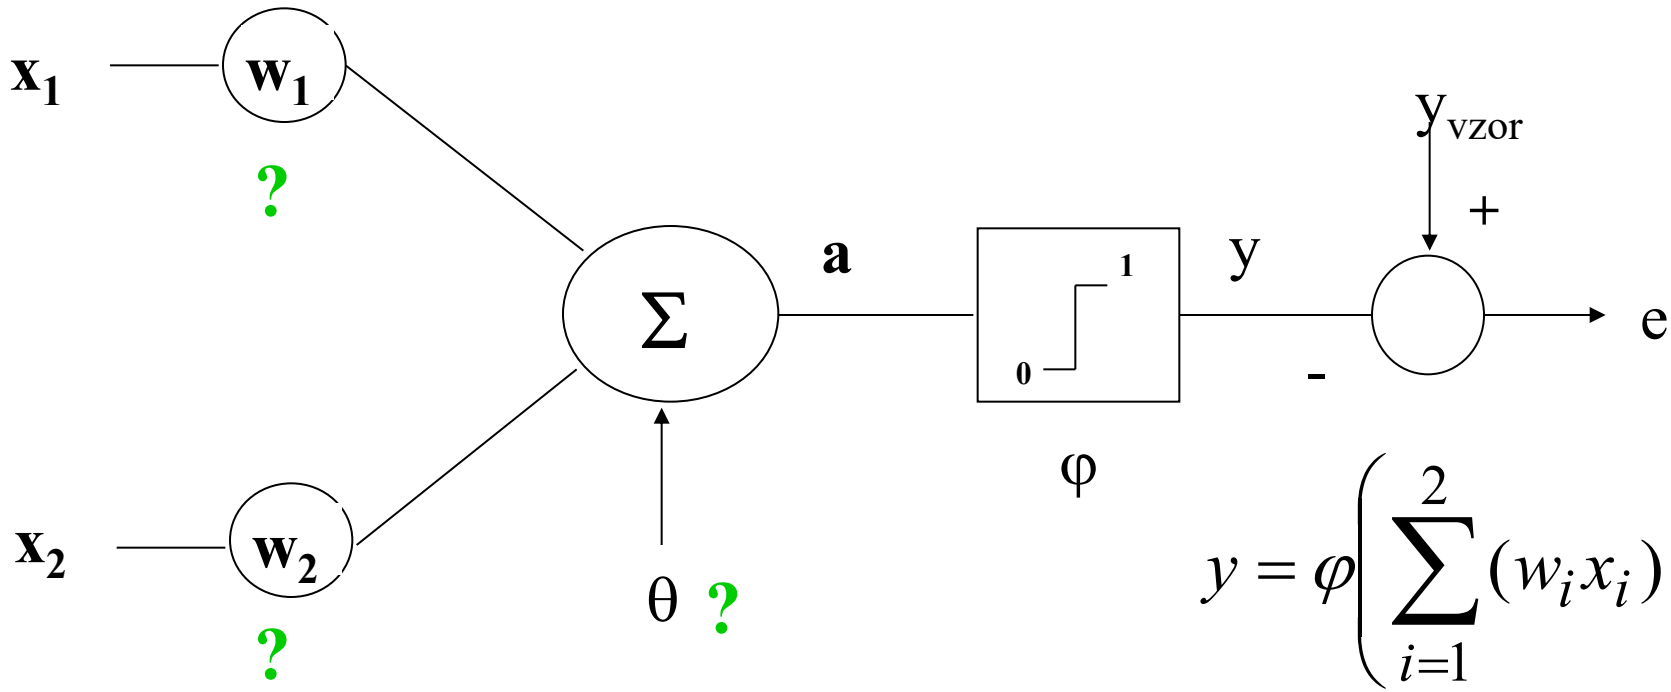

$$y = \varphi\left(\sum_{i=1}^{2}(w_i x_i) - \theta\right)$$

Logická funkcia AND

(trénovacie vzory)

vzor	x_1	x_2	y_{vzor}
v_1	0	0	0
v_2	0	1	0
v_3	1	0	0
v_4	1	1	1

Postup trénovania

1. **<u>Inicializácia:</u> nastavíme váhy w_1, w_2, θ na náhodné hodnoty z rozsahu (-0,5 ; 0,5).**
2. **<u>Výpočet</u> výstupu y(v) pri vstupe vzoru v_1 (v_i)**
3. **<u>Výpočet</u> chyby $e = y_{vzor} - y$.**
4. **<u>Korekcia váh</u>: $w_{j,new} = w_j + \Delta w_j$**

   $$\Delta w_j = \alpha . x_j . e \; ; \quad j=1, 2$$
5. **Choď na ďalší vzor (v_2, v_3, v_4)**
6. **Cyklus krokov 2-5 („epocha“) opakuj, kým chyba modelu nebude dostatočne malá.**

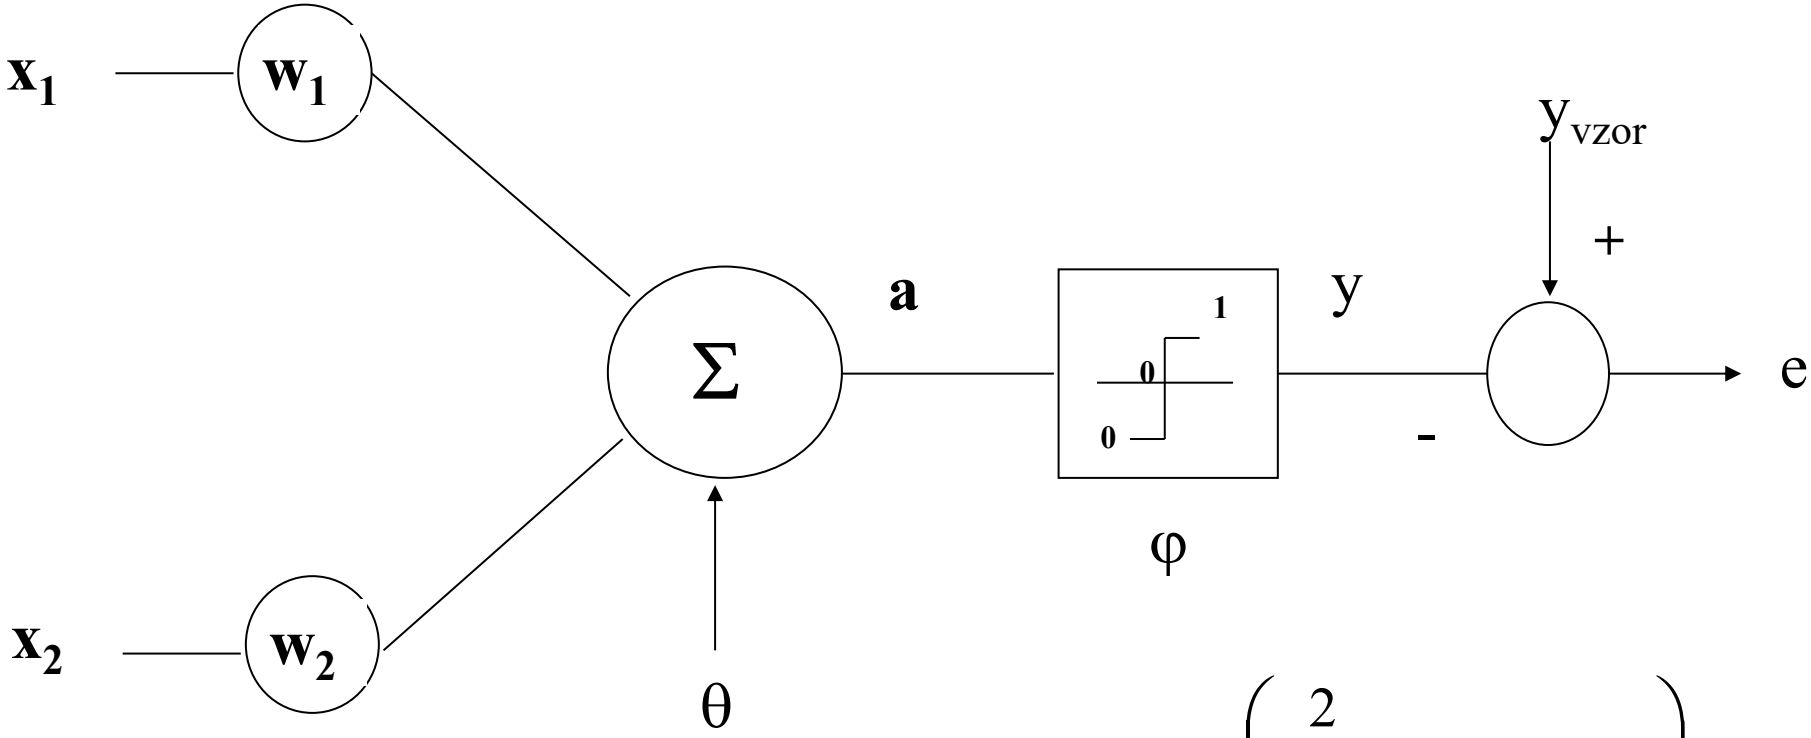

$$y = \varphi\left(\sum_{i=1}^{2}(w_i x_i) - \theta\right)$$

$$\boxed{\begin{array}{l} w_{j,new} = w_j + \Delta w_j \\ \Delta w_j = \alpha . x_j . e \; ; \qquad j=1, 2 \end{array}}$$

Epocha	x_1	x_2	Požad. y_v	Staré w_1	Staré w_2	Aktual. y	Chyba $e=y_v-y$	Nové w_1	Nové w_2
1	0	0	0	0,3	-0,1	0	0	0,3	-0,1
	0	1	0	0,3	-0,1	0	0	0,3	-0,1
	1	0	0	0,3	-0,1	1	*-1*	0,2	-0,1
	1	1	1	0,2	-0,1	0	1	0,3	0
2	0	0	0	0,3	0	0	0	0,3	0
	0	1	0	0,3	0	0	0	0,3	0
	1	0	0	0,3	0	1	*-1*	0,2	0
	1	1	1	0,2	0	1	0	0,2	0
3	0	0	0	0,2	0	0	0	0,2	0
	0	1	0	0,2	0	0	0	0,2	0
	1	0	0	0,2	0	1	*-1*	0,1	0
	1	1	1	0,1	0	0	*1*	0,2	0,1
4	0	0	0	0,2	0,1	0	0	0,2	0,1
	0	1	0	0,2	0,1	0	0	0,2	0,1
	1	0	0	0,2	0,1	1	*-1*	0,1	0,1
	1	1	1	0,1	0,1	1	0	0,1	0,1
5	0	0	0	0,1	0,1	0	0	0,1	0,1
	0	1	0	0,1	0,1	0	0	0,1	0,1
	1	0	0	0,1	0,1	0	0	0,1	0,1
	1	1	1	0,1	0,1	1	0	0,1	0,1

$\alpha=0,1$

$\theta=0,2$

$w_{j,new} = w_j + \Delta w_j \qquad \Delta w_j = \alpha . x_j . e \; ; \qquad j=1, 2$

1. riadok tabuľky (1.epocha)

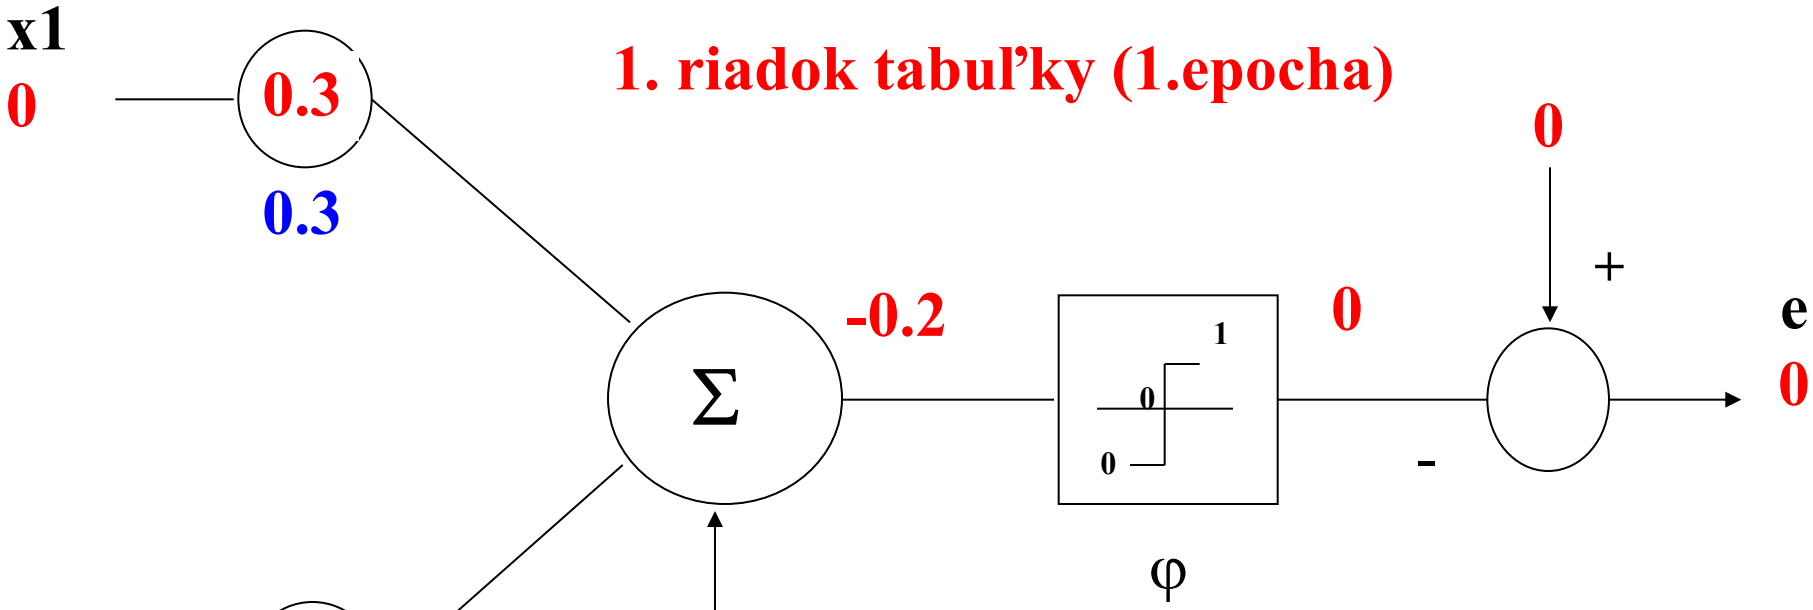

$$y = \varphi\left(\sum_{i=1}^{2}(w_i x_i) - \theta\right)$$

$\Delta w_j = 0.1 x_j e = 0$; $j=1, 2$

$w_{j,new} = w_j + \Delta w_j = 0.3$ resp. -0.1

3. riadok tabuľky (1.epocha)

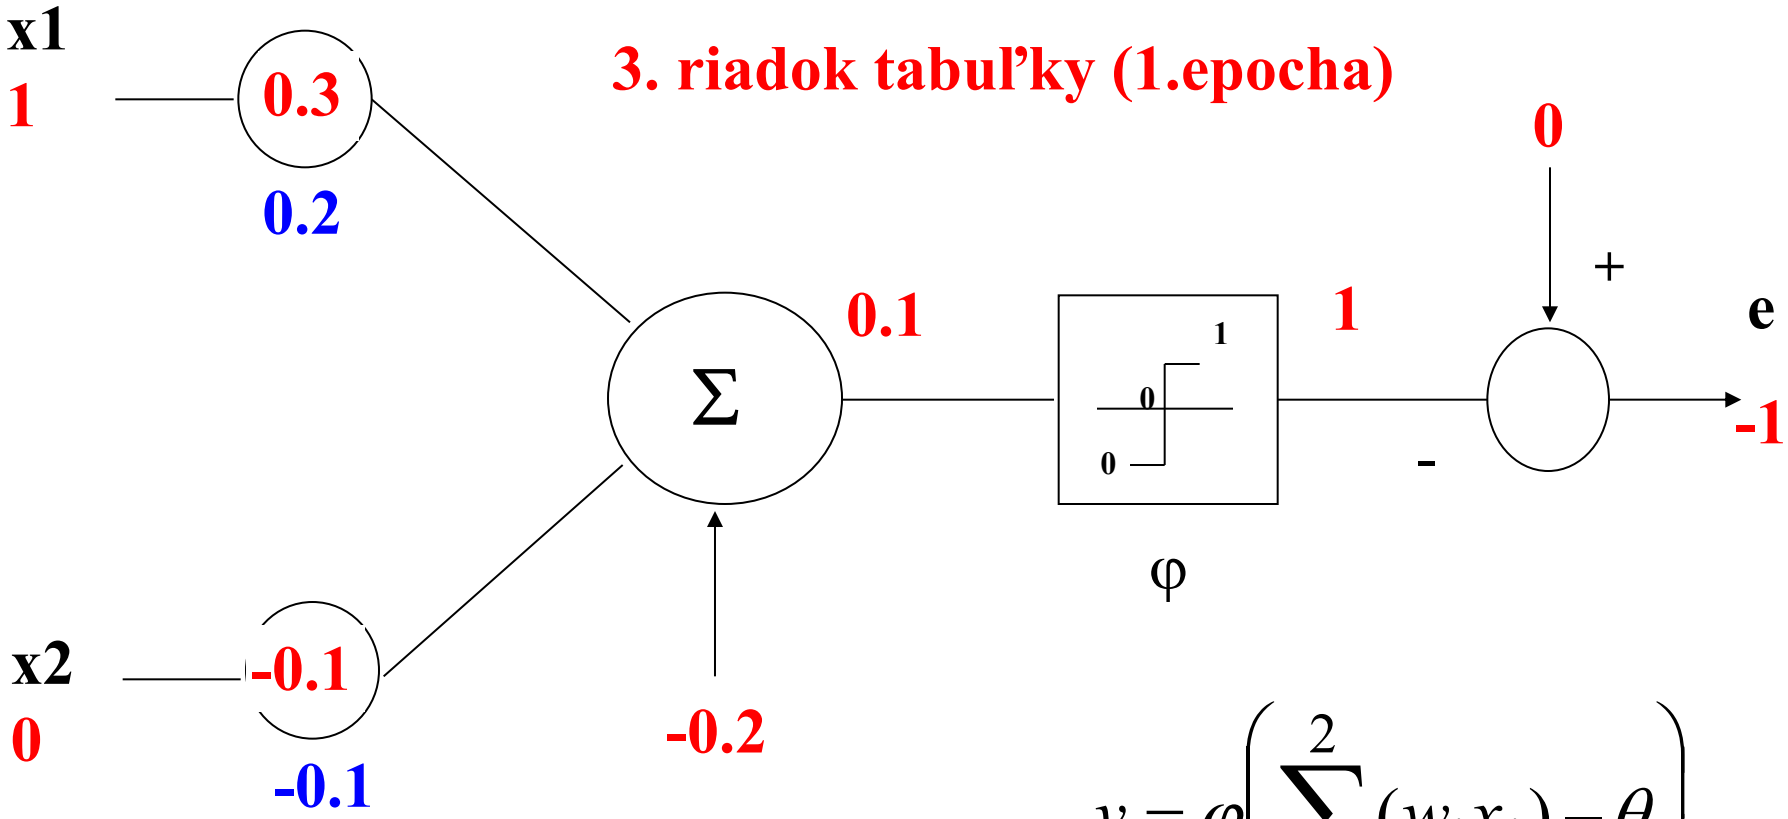

$$y = \varphi\left(\sum_{i=1}^{2}(w_i x_i) - \theta\right)$$

$\Delta w_j = 0.1 x_j e = -0.1$; $j=1, 2$

$w_{j,new} = w_j + \Delta w_j = 0.3-0.1=0.2$ resp. -0.1

Epocha	x_1	x_2	Požad. y_v	Staré w_1	Staré w_2	Aktual. y	Chyba $e=y_v-y$	Nové w_1	Nové w_2
1	0	0	0	0,3	-0,1	0	0	0,3	-0,1
	0	1	0	0,3	-0,1	0	0	0,3	-0,1
	1	0	0	0,3	-0,1	1	*-1*	0,2	-0,1
	1	1	1	0,2	-0,1	0	1	0,3	0
2	0	0	0	0,3	0	0	0	0,3	0
	0	1	0	0,3	0	0	0	0,3	0
	1	0	0	0,3	0	1	*-1*	0,2	0
	1	1	1	0,2	0	1	0	0,2	0
3	0	0	0	0,2	0	0	0	0,2	0
	0	1	0	0,2	0	0	0	0,2	0
	1	0	0	0,2	0	1	*-1*	0,1	0
	1	1	1	0,1	0	0	*1*	0,2	0,1
4	0	0	0	0,2	0,1	0	0	0,2	0,1
	0	1	0	0,2	0,1	0	0	0,2	0,1
	1	0	0	0,2	0,1	1	*-1*	0,1	0,1
	1	1	1	0,1	0,1	1	0	0,1	0,1
5	0	0	0	0,1	0,1	0	0	0,1	0,1
	0	1	0	0,1	0,1	0	0	0,1	0,1
	1	0	0	0,1	0,1	0	0	0,1	0,1
	1	1	1	0,1	0,1	1	0	0,1	0,1

$\alpha=0,1$

$\theta=-0,2$

$w_{j,new} = w_j + \Delta w_j \qquad \Delta w_j = \alpha . x_j . e \; ; \qquad j=1, 2$

Neurónový And

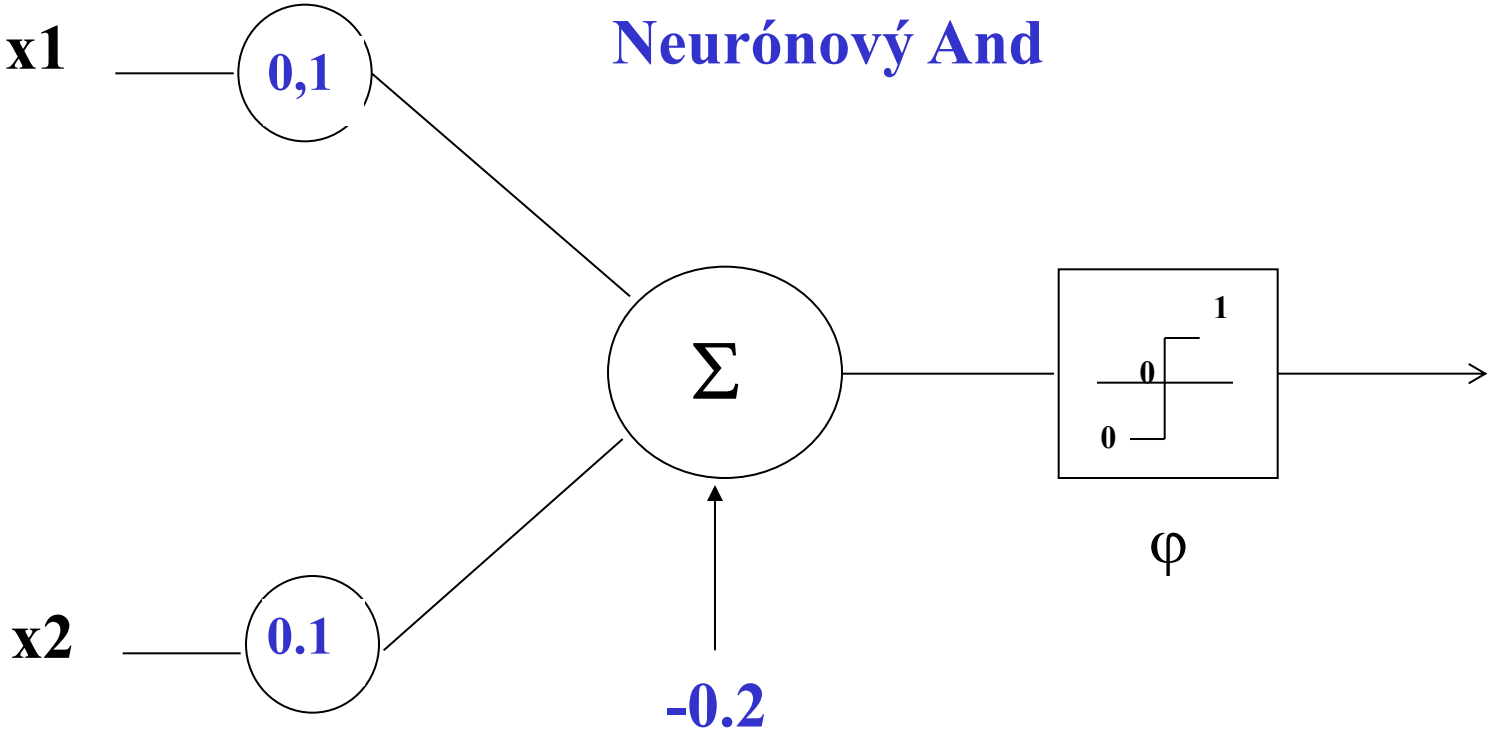

$$y = \varphi\left(\sum_{i=1}^{2}(w_i x_i) - \theta\right)$$

2.7 Viacvrstvové perceptrónové siete (Multilayer Perceptron networks - MLP)

Neurón

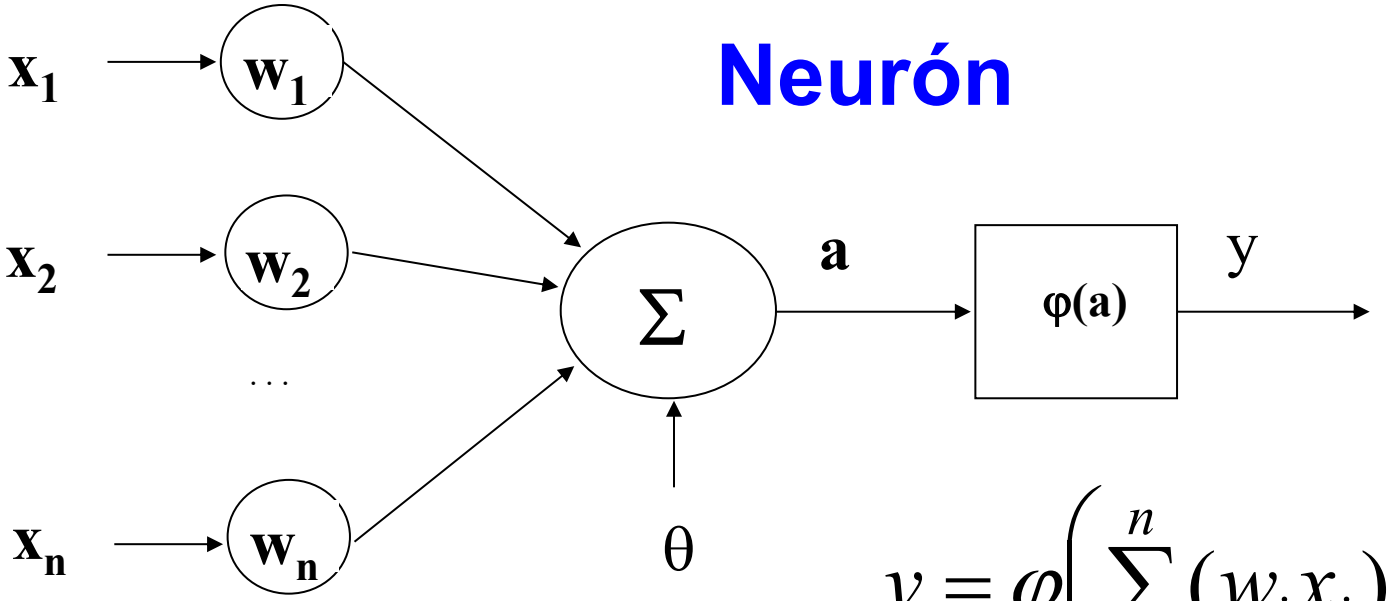

$$y = \varphi\left(\sum_{i=1}^{n}(w_i x_i) - \theta\right) = \varphi(a)$$

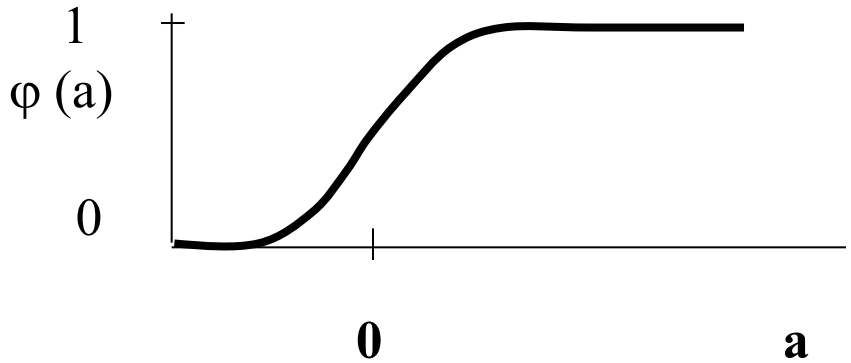

$$\varphi(a) = \frac{1}{1 + e^{-\beta a}}$$

Sigmoida

x_i - vstupy neurónu

w_i - váhy synaptických spojení

θ - prah (citlivosti) neurónu

a - vnútorná aktivita neurónu

φ - aktivačná funkcia neurónu

y - výstup neurónu

Neurónová sieť MLP

- Obsahuje aspoň jednu skrytú vrstvu neurónov.
- Neuróny väčšinou obsahujú spojitú nelineárnu aktivačnú funkciu (obyčajne sigmoidu alebo hyperbolický tangens).
- 3-vrstvové siete sú schopné aproximovať ľubovoľnú spojitú nelineárnu funkciu (transformáciu).
- 4-vrstvové siete sú schopné aproximovať ľubovoľnú nespojitú nelineárnu funkciu (transformáciu).
- Parametrizácia takýchto sietí sa realizuje trénovaním neurónovej siete algoritmom "spätného šírenia chyby„ (učenie s učiteľom).

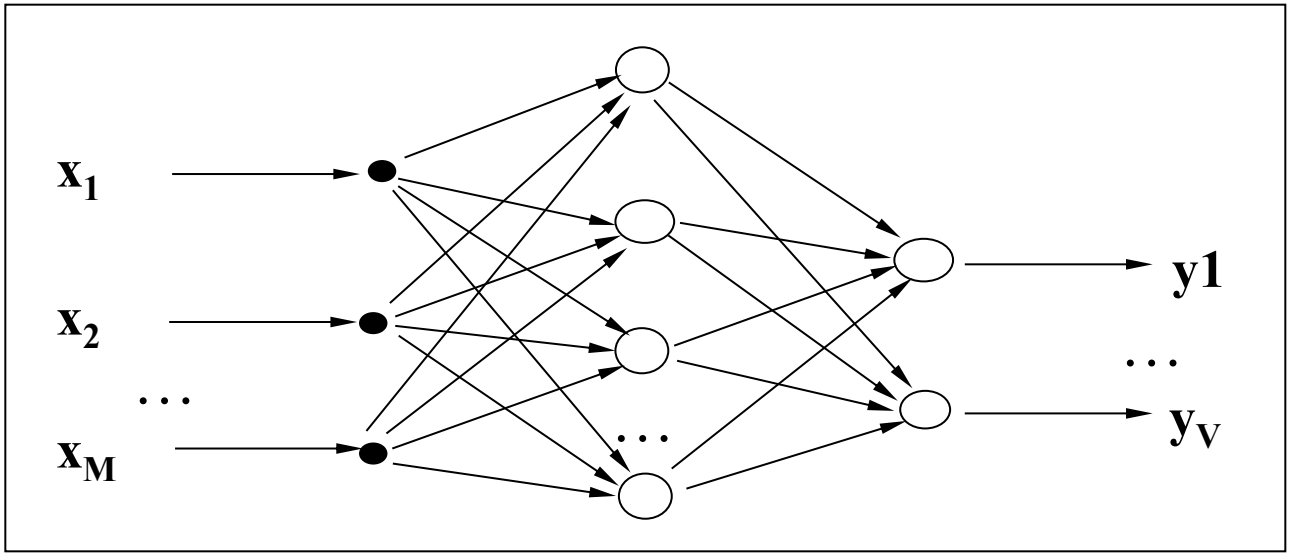

$y=f(x)$

Trénovanie MLP :
Algoritmus spätného šírenia chyby
(„Back- Propagation“)

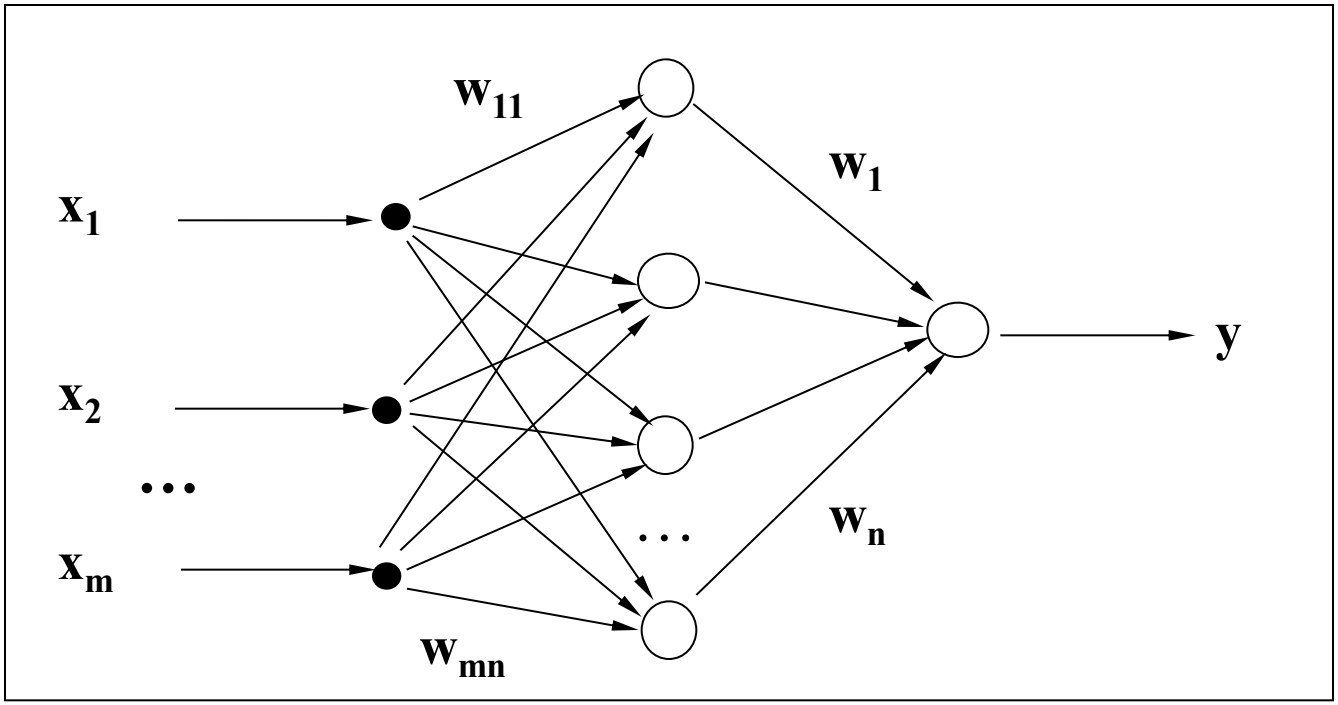

w_{ij}=? ; w_j=?

Globálna chyba siete E → min

$$E = \sum_{p=1}^{N} \varepsilon = \sum_{p=1}^{N} \frac{1}{2} \sum_{k=1}^{V} e_k^2$$

N - počet vzoriek trénovacej množiny, V - počet neurónov vo výstupnej vrstve

α – krok učenia

$$e_k = d_k - y_k$$

$$\Delta w = \alpha \frac{\delta E}{\delta w_{ij}}$$

Výpočet váh w sa uskutočňuje iteračným algoritmom, kde sa postupne počítajú korekcie každej váhy Δw ; w(t)=w(t-1)+ Δw

Predpokladajme trénovaciu množinu (vstupno/výstupných) dát
$D=\{x_{pq},d_{pr}\}$;

p=1,...,N je počet vzoriek
q=1,...,M je počet vstupov siete
r=1,...,V je počet výstupov siete

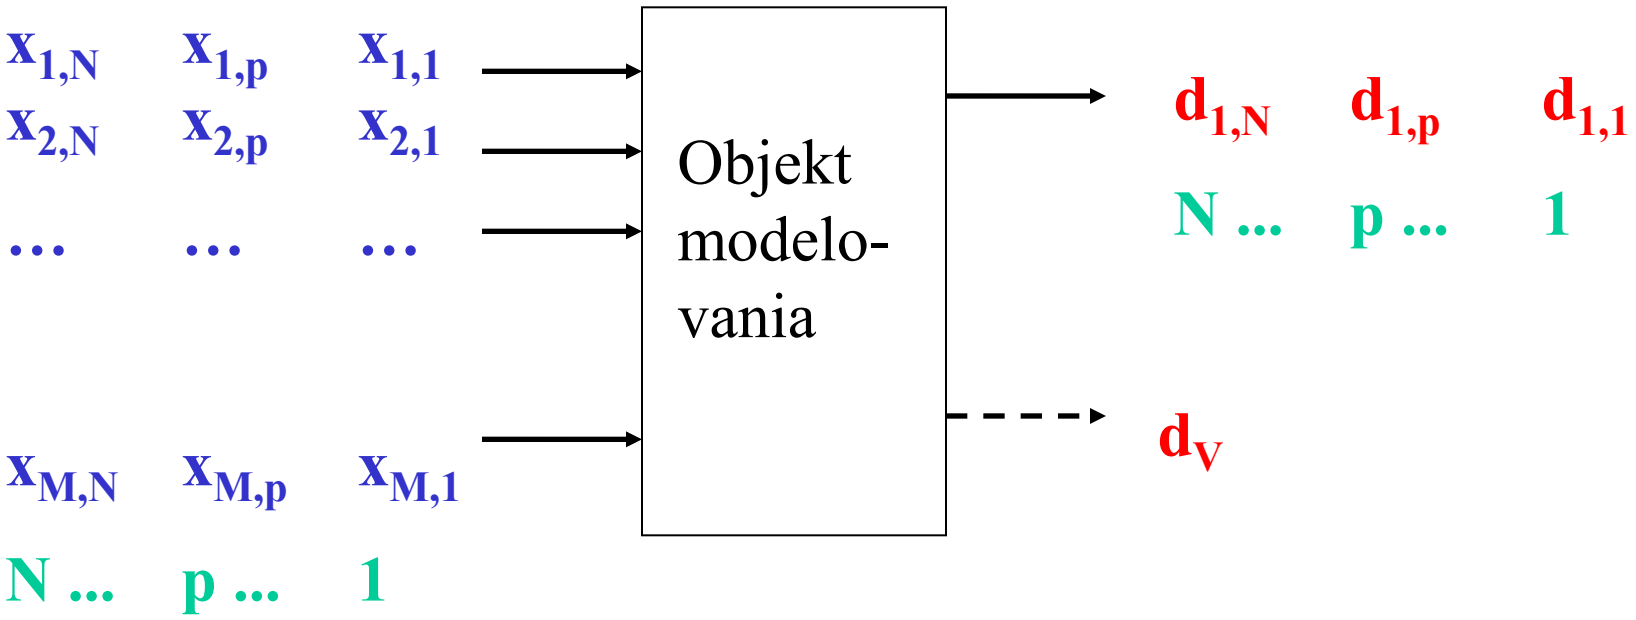

Číslo vzorky **vstupy** **(požadované) výstupy**

Trénovanie (parametrizácia) neurónovej siete prebieha vo viacerých cykloch („vlnách“) - tzv. EPOCHÁCH.

V každej epoche sa postupne cez sieť prešíri celá postupnosť trénovacích vzoriek x_p (postupnosť vstupných vektorov), porovnáva sa so skutočnými výstupmi a na základe odchýliek sa upravujú parametre siete).

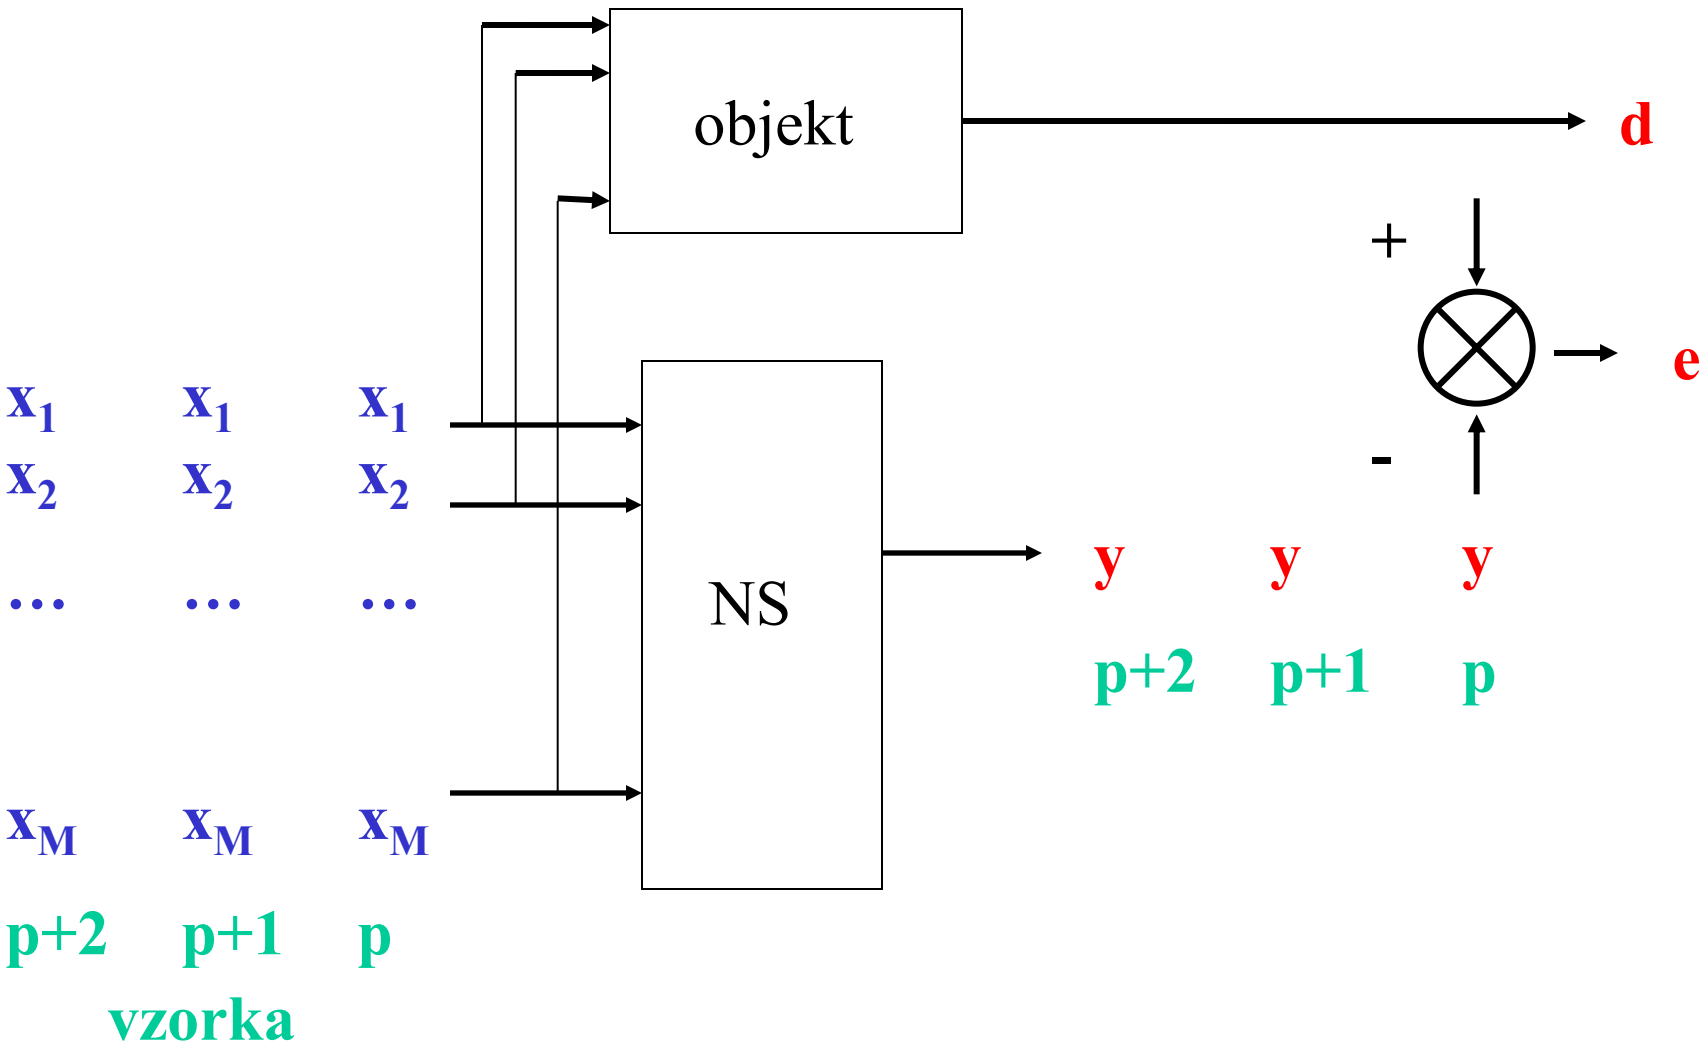

1 epocha: p=1,2,…,N

Algoritmus trénovania UNS

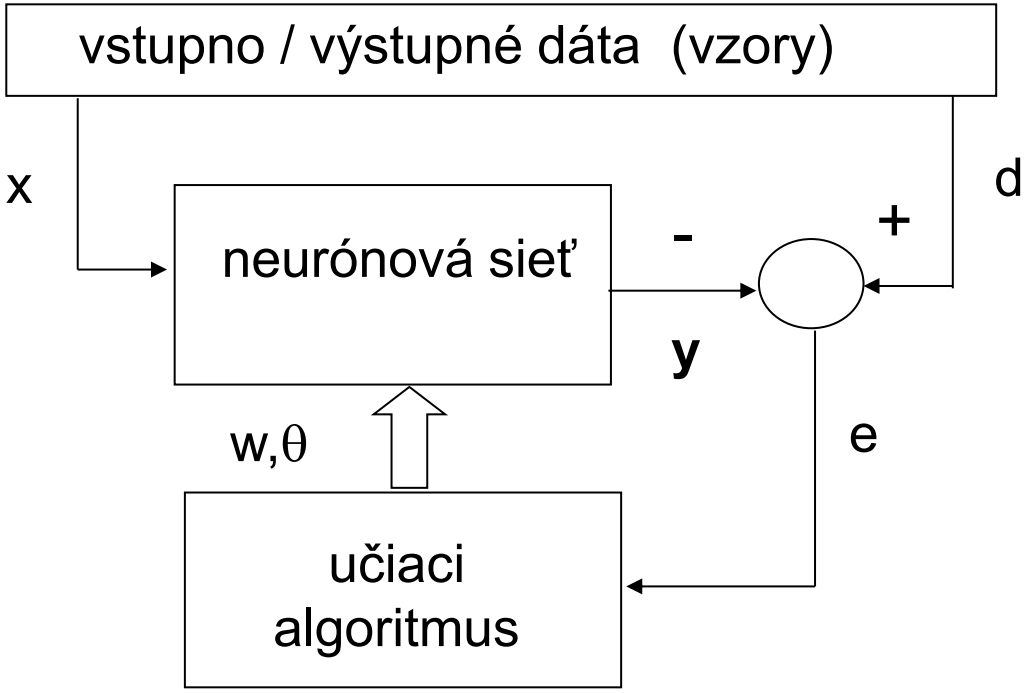

Dopredná fáza šírenia signálov v neurónovej sieti

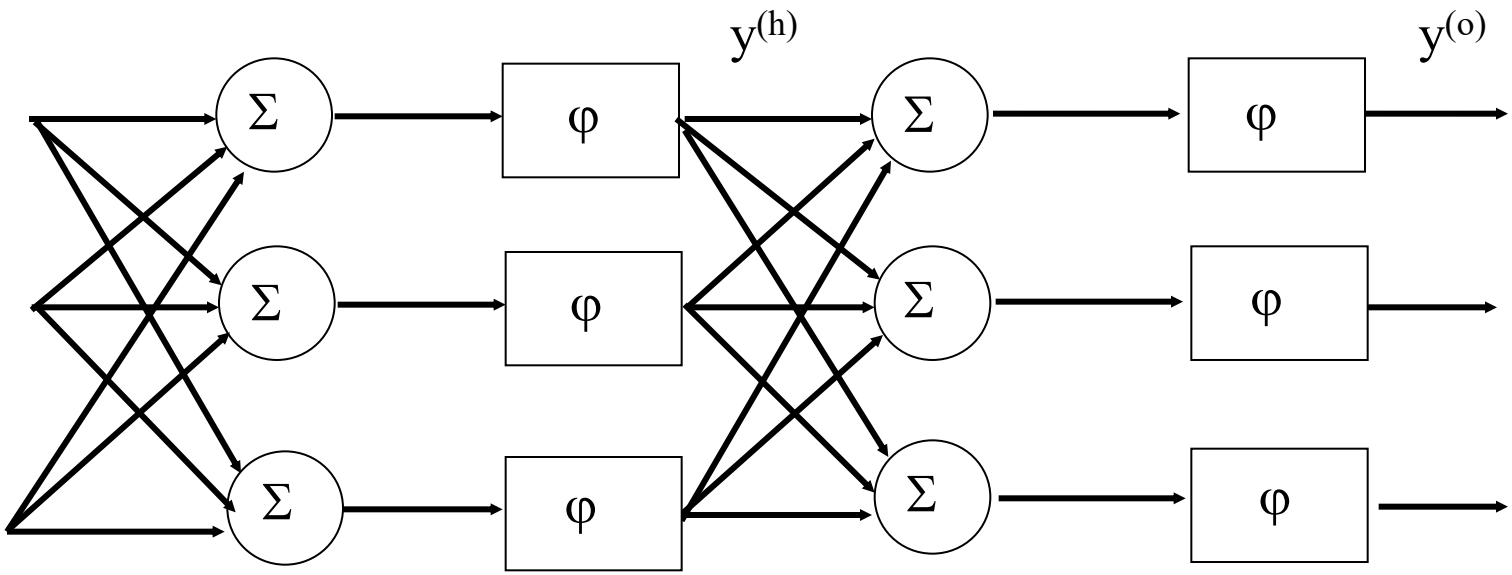

(h) – index neurónov skrytej vrstvy (hidden),
(o) – index neurónov výstupnej vrstvy (output)

Spätná fáza šírenia signálov v neurónovej sieti

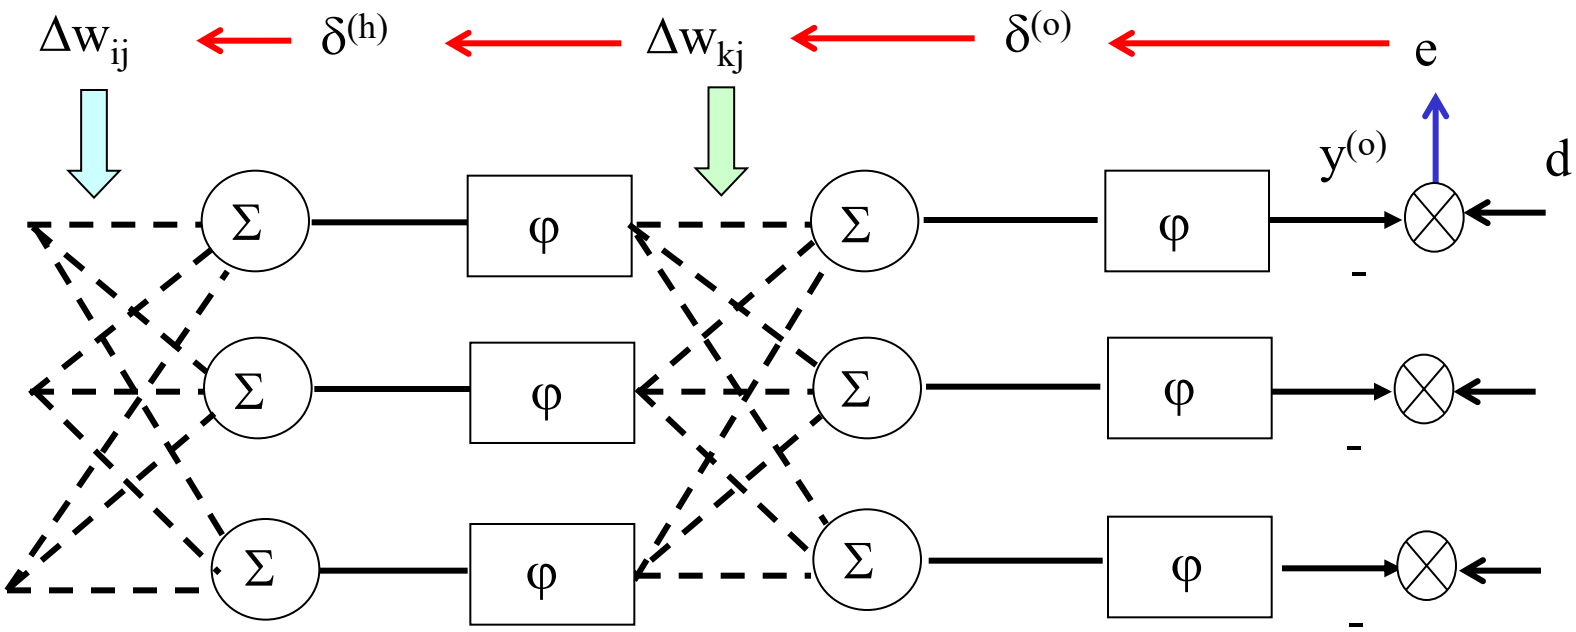

$$\boxed{\Delta w_{kj} = \eta \delta_k y_j}$$ - korekcia váh výstupného neurónu

$$\boxed{\delta_k =} -\frac{\partial \varepsilon}{\partial e_k}\frac{\partial e_k}{\partial y_k}\frac{\partial y_k}{\partial a_k} = \boxed{e_k \varphi'(a_k)}$$

Lokálny gradient neurónu vo výstup. vrstve

$$\boxed{\Delta w_{ji} = \eta \delta_j y_i}$$ - úprava váh neurónov v skrytej vrstve

$$\boxed{\delta_j = \varphi'(a_j)\sum_{k=1}^{V} \delta_k w_{kj}}$$

Lokálny gradient pre skrytý neurón